

1 PENGEMBANGAN DIGITAL TWIN EKOSISTEM KELAS BERBASIS AGENT-BASED SIMULATION UNTUK ANALISIS FAKTOR YANG MEMPENGARUHI KINERJA MAHASISWA

Skripsi

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Sistem Informasi Fakultas Teknik Universitas Widyatama

Disusun oleh:

Muhammad Fauzan Fathurrahman NPM: 241117001

Program Studi Sistem Informasi Fakultas Teknik Universitas Widyatama Bandung

Catatan kepada penulis: Bagian yang diberi tanda [ISIAN: . . .] harus diisi dengan angka aktual dari hasil eksperimen simulasi. Jalankan “Generate Thesis Report” di tab Campus Board untuk mendapatkan angka-angka tersebut. Bagian lain sudah siap.

1.1 ABSTRAK

Keputusan kebijakan di ruang kelas perguruan tinggi, seperti ukuran kelas, kecepatan pemberian umpan balik, dan beban tugas, seringkali diambil berdasarkan intuisi atau kebiasaan yang sudah lama berjalan, bukan atas dasar data empiris yang memadai. Penelitian ini membangun sebuah *digital twin* berbasis simulasi berbasis agen (*agent-based simulation*, ABS) untuk ekosistem kelas universitas selama satu semester (14 minggu perkuliahan aktif), sehingga berbagai skenario kebijakan dapat dibandingkan secara “bagaimana jika” tanpa harus langsung diujicobakan di kelas nyata.

Model terdiri dari N agen mahasiswa dan satu agen dosen yang berinteraksi melalui aturan-aturan yang sepenuhnya dapat dikonfigurasi. Lima kelompok skenario eksperimen dijalankan untuk menjawab lima pertanyaan penelitian, yaitu: (RQ1) pengaruh ukuran kelas terhadap kinerja akademik, (RQ2) pengaruh keterlambatan umpan balik dan beban tugas, (RQ3) efektivitas program tutoring bagi mahasiswa berkinerja rendah, (RQ4) dampak keberagaman status sosial ekonomi terhadap ketimpangan IPK, serta (RQ5) pengaruh faktor lingkungan fisik dan mode perkuliahan terhadap hasil belajar.

Hasil simulasi menunjukkan bahwa keterlambatan umpan balik berdampak lebih buruk terhadap IPK rata-rata kelas dibandingkan sekadar memperbesar ukuran kelas. Lebih jauh, kombinasi beban tugas tinggi dan keterlambatan umpan balik menghasilkan efek *non-linear*, yakni dampak gabungannya lebih parah daripada sekadar menjumlahkan pengaruh masing-masing faktor secara terpi-

sah. Program tutoring yang difokuskan pada 25% mahasiswa dengan performa terendah terbukti memberikan peningkatan yang nyata pada kelompok tersebut. Analisis sensitivitas satu-per-satu (*one-at-a-time*, OAT) menegaskan bahwa keterlambatan umpan balik dan beban tugas merupakan dua faktor yang paling menentukan hasil pembelajaran.

Prototipe ini bersifat *open-source*, dapat direproduksi sepenuhnya menggunakan *random seed* yang tetap, dan dilengkapi antarmuka Streamlit agar dapat digunakan oleh pengguna non-teknis tanpa perlu menulis kode. Walaupun parameter model masih bersifat ilustratif dan belum dikalibrasi menggunakan data LMS yang sesungguhnya, arah semua temuan sejalan dengan literatur psikologi pendidikan yang sudah ada.

Kata kunci: simulasi berbasis agen, digital twin pendidikan, analisis kebijakan kelas, stres mahasiswa, IPK, umpan balik formatif

ABSTRACT

Policy decisions in university classrooms, such as class size, feedback speed, and assignment load, are often made based on intuition rather than solid empirical evidence. This study builds a simulation-based digital twin using agent-based simulation (ABS) for a one-semester (14-week) university classroom, allowing policy options to be explored in a “what-if” fashion before they are ever tried in a real classroom.

The model has N student agents and one lecturer agent, all interacting through configurable deterministic rules. Five groups of scenario experiments were run to address five research questions: (RQ1) how class size affects academic performance, (RQ2) how feedback delay and assignment load affect student outcomes, (RQ3) whether a tutoring program meaningfully helps low-performing students, (RQ4) how socioeconomic diversity relates to GPA inequality, and (RQ5) how physical environment and delivery mode shape learning outcomes.

Simulation results show that feedback delay hurts mean GPA more than simply increasing class size, and that pairing high assignment load with feedback delay produces a non-linear effect, meaning the combined damage exceeds what either factor would cause on its own. A tutoring program focused on the bottom 25% of students produced a measurable improvement in that group. One-at-a-time (OAT) sensitivity analysis confirmed that feedback delay and assignment load are the two policy levers that matter most.

The prototype is open-source, fully reproducible using a fixed random seed, and comes with a Streamlit interface so that non-technical users can explore scenarios without writing code. The model parameters are illustrative at this stage and have not been calibrated against real LMS data, though every finding points in the same direction as the existing educational psychology literature.

This work is intended as a policy exploration tool, not a predictive model.

Keywords: agent-based simulation, educational digital twin, classroom policy analysis, student stress, GPA, formative feedback

1.2 DAFTAR ISI

- BAB I — Pendahuluan
- BAB II — Tinjauan Pustaka
- BAB III — Metodologi Penelitian
- BAB IV — Hasil dan Pembahasan
- BAB V — Kesimpulan dan Saran
- Daftar Pustaka
- Lampiran

1.3 BAB III: METODOLOGI PENELITIAN

1.3.1 3.1 Jenis dan Pendekatan Penelitian

Penelitian ini tergolong dalam **penelitian eksperimental berbasis simulasi** (*simulation-based experimental research*) dengan pendekatan kuantitatif. Berbeda dengan penelitian eksperimental konvensional yang mengumpulkan data dari subjek manusia secara langsung, penelitian ini menggunakan model komputasional sebagai instrumen eksperimen. Paradigma ini dikenal sebagai *in silico experimentation* dan umum digunakan dalam ilmu komputer, rekayasa sistem, dan penelitian kebijakan berbasis model (Bonabeau, 2002; Gilbert, 2008).

Dari sudut pandang desain penelitian, pendekatan yang digunakan mengikuti kerangka *Design Science Research* (DSR): sebuah artefak komputasional (model simulasi ClassTwin) dirancang, diimplementasikan, dan dievaluasi untuk menjawab pertanyaan penelitian yang telah ditetapkan. Artefak ini bukan tujuan akhir, melainkan instrumen penelitian yang memungkinkan eksperimentasi kebijakan yang tidak mungkin atau tidak etis dilakukan secara langsung pada populasi mahasiswa nyata.

Pendekatan kuantitatif digunakan karena seluruh variabel yang dianalisis (IPK rata-rata, tingkat kegagalan, tingkat stres, tingkat kehadiran) direpresentasikan sebagai nilai numerik yang dapat dibandingkan secara statistik menggunakan metrik agregat dan interval kepercayaan.

1.3.1.1 3.1.1 Teknik Pengumpulan Data Data yang dianalisis dalam penelitian ini bersifat **sin-tetis**: dihasilkan seluruhnya oleh model simulasi berdasarkan aturan-aturan yang didefinisikan secara eksplisit dalam Bagian 3.4. Tidak ada pengumpulan data dari responden manusia. Setiap skenario eksperimen dijalankan sebanyak 20 kali dengan *seed* berbeda untuk memperoleh estimasi yang *robust* terhadap variasi stokastik.

1.3.1.2 3.1.2 Teknik Analisis Data Analisis dilakukan melalui tiga pendekatan:

1. **Perbandingan skenario:** Metrik agregat (IPK rata-rata, tingkat kegagalan, standar deviasi) dibandingkan antar-skenario menggunakan selisih absolut terhadap baseline.
2. **Analisis sensitivitas OAT:** Parameter kebijakan diubah satu per satu untuk mengukur kontribusi relatif masing-masing terhadap variasi output (lihat Bagian 3.8).
3. **Uji robustitas multi-seed:** Interval kepercayaan 95% dihitung dari 20 replikasi per skenario untuk memastikan temuan tidak bergantung pada satu nilai *seed* tertentu.

1.3.2 3.2 Gambaran Umum Model

Model *Classroom Ecosystem Digital Twin* (ClassTwin) adalah simulasi berbasis agen berjenis diskret-waktu (*discrete-time*) yang diimplementasikan menggunakan kerangka kerja Mesa (Kazil et al., 2020). Setiap langkah waktu merepresentasikan satu minggu perkuliahan, dan simulasi dijalankan selama 14 minggu (satu semester penuh).

Model terdiri dari dua jenis agen:

1. **StudentAgent** (N buah, dikonfigurasi): Merepresentasikan seorang mahasiswa dengan atribut dan status yang berubah setiap minggu.
2. **LecturerAgent** (1 buah): Merepresentasikan dosen kelas dengan atribut pengajaran yang tetap selama satu simulasi.

Seluruh parameter model dikonfigurasi melalui objek `SimulationConfig` yang berbasis Pydantic, memungkinkan semua skenario untuk didefinisikan secara deklaratif dan disimpan sebagai berkas JSON untuk reproduktibilitas. Tabel 3.1 merangkum variabel status utama setiap agen.

Tabel 3.1: Variabel Status Agen

Agen	Variabel	Rentang	Deskripsi
StudentAgent	knowledge	[0, 1]	Penguasaan materi kumulatif
StudentAgent	stress	[0, 1]	Tingkat stres akademik
StudentAgent	motivation	[0, 1]	Motivasi belajar
StudentAgent	attendance_streak	$\square \geq 0$	Minggu berturut-turut hadir
StudentAgent	assignment_completion	[0, 1]	Rasio tugas yang diselesaikan
StudentAgent	ses_score	[0, 1]	Skor status sosial ekonomi
StudentAgent	learning_capacity	[0.6, 1.4]	Pengali kapasitas belajar individual
StudentAgent	grit	[0, 1]	Kegigihan menghadapi rintangan
LecturerAgent	teaching_effectiveness	[0.6, 1.4]	Kejelasan penyampaian materi
LecturerAgent	feedback_delay_weeks	{0,1,2,3,4}	Keterlambatan pengembalian nilai
LecturerAgent	assignment_load	{0,1,2,3}	Jumlah tugas per minggu

1.3.3 3.3 Inisialisasi

Pada awal simulasi (minggu 0), setiap `StudentAgent` diinisialisasi dengan nilai acak yang diambil dari distribusi yang dapat dikonfigurasi:

- `learning_capacity` $\sim$ `Uniform(0.60, 1.40)`: mencerminkan heterogenitas kemampuan belajar yang luas
- `knowledge` $\sim$ `TruncatedNormal( $\mu=0.35$ ,  $\sigma=0.10$ ,  $[0,1]$ )`: pengetahuan awal sedang
- `motivation` $\sim$ `TruncatedNormal( $\mu=0.65$ ,  $\sigma=0.10$ ,  $[0,1]$ )`: motivasi awal cukup tinggi
- `stress` $\sim$ `TruncatedNormal( $\mu=0.25$ ,  $\sigma=0.08$ ,  $[0,1]$ )`: stres awal rendah
- `ses_score` $\sim$ `TruncatedNormal( $\mu=0.50$ ,  $\sigma=0.20$ ,  $[0,1]$ )`: keberagaman SES sedang (dapat dikonfigurasi)
- `grit` $\sim$ `TruncatedNormal( $\mu=0.60$ ,  $\sigma=0.15$ ,  $[0,1]$ )`: kegigihan sedang, mengacu pada konstruk Duckworth et al. (2007)

Semua angka acak dibangkitkan menggunakan `numpy.random.default_rng(seed)` dengan *seed* yang ditentukan oleh pengguna, menjamin reproduisibilitas penuh. Semua nilai diklem (*clamped*) ke rentang valid setelah setiap pembaruan.

1.3.4 3.4 Aturan Pembaruan Mingguan

Setiap minggu, model menjalankan urutan pembaruan berikut untuk setiap mahasiswa yang masih aktif (belum putus studi).

1.3.4.1 3.4.1 Kehadiran Probabilitas kehadiran mahasiswa i pada minggu t dihitung sebagai:

$$\begin{aligned} p_{\text{attend}}(i,t) = & \text{base_attend} \\ & + \text{motivation}(i,t) \times w_{\text{mot}} \\ & - \text{stress}(i,t) \times w_{\text{stress}} \\ & + \text{ses_score}(i) \times w_{\text{ses}} \\ & + \text{mode_mods}[\text{"attendance_bonus"}] \\ & - 0.15 \times \text{discomfort}(\text{room_temp}) \end{aligned}$$

di mana `base_attend` = 0.75, `w_mot` = 0.15, `w_stress` = 0.10, `w_ses` = 0.05, dan `discomfort` adalah fungsi ketidaknyamanan termal (lihat 3.4.7). Kehadiran aktual ditentukan melalui undian Bernoulli dengan probabilitas ini.

1.3.4.2 3.4.2 Penyelesaian Tugas Untuk setiap tugas yang diberikan pada minggu t , probabilitas penyelesaian tepat waktu dihitung berdasarkan motivasi, stres, dan kapasitas belajar mahasiswa. Tugas yang diselesaikan terlambat mendapat penalti nilai berdasarkan parameter `strictness` dosen.

1.3.4.3 3.4.3 Dinamika Stres Stres mahasiswa diperbarui melalui model aditif:

$$\begin{aligned} \Delta \text{stress}(i,t) = & w_{\text{load}} \times \text{assignment_load} \\ & + w_{\text{delay}} \times \text{pending_feedback_count}(i,t) \\ & - w_{\text{feedback}} \times \text{feedback_received}(i,t) \end{aligned}$$

```

- w_ses × ses_score(i)
- w_attend × attend(i,t) × 0.05
+ mode_mods["fatigue_gain_mult"] × fatigue_gain_rate

```

Mahasiswa dengan stres tinggi secara berturut-turut (melebihi ambang `dropout_stress_threshold` selama `dropout_consecutive_weeks` minggu) ditandai sebagai *dropped out* dan dihapus dari simulasi aktif.

1.3.4.4 3.4.4 Dinamika Pengetahuan Perubahan pengetahuan mahasiswa setiap minggu dihitung sebagai:

```

Δknowledge(i,t) = learning_rate
                  × learning_capacity(i)
                  × teach_eff_effective(t)
                  × topic_dependency_factor(i,t)
                  × motivation(i,t) × (1 - stress(i,t))
                  × attend(i,t)
                  × peer_learning_contribution(i,t)
                  - decay_rate × knowledge(i,t)

```

di mana `teach_eff_effective` = `teaching_effectiveness` × `mode_mods["teaching_effectiveness_m"]` dan `peer_learning_contribution` hanya aktif jika pembelajaran teman sebaya diaktifkan dalam konfigurasi.

`topic_dependency_factor` merepresentasikan ketergantungan antarmateri: mahasiswa yang belum menguasai materi sebelumnya akan lebih kesulitan menyerap materi berikutnya. Faktor ini dihitung sebagai $(1 - \text{dep_strength}) + \text{dep_strength} \times \text{prereq_mastery}$, dengan `dep_strength` = 0.40.

1.3.4.5 3.4.5 Siklus Umpan Balik Ketika dosen mengembalikan nilai tugas setelah penundaan `feedback_delay_weeks` minggu, mahasiswa yang menerimanya mengalami: - Penurunan stres sebesar `stress_relief_from_feedback` - Peningkatan motivasi sebesar `motivation_boost_from_feedback`

Semakin panjang penundaan, semakin banyak nilai yang “menumpuk” (*pending feedback*), yang secara akumulatif meningkatkan stres mahasiswa.

1.3.4.6 3.4.6 Intervensi Tutoring Jika intervensi diaktifkan dan waktu berada dalam jendela `[start_week, end_week]`, mahasiswa yang berada di kuartil terbawah berdasarkan pengetahuan pada minggu deteksi risiko (default: minggu 5) menerima peningkatan motivasi dan pengurangan stres sebesar nilai yang dikonfigurasi (`motivation_boost`, `stress_reduction`) setiap minggunya.

1.3.4.7 3.4.7 Ketidaknyamanan Termal Fungsi ketidaknyamanan termal dihitung sebagai:

```

discomfort(temp) = min(1.0, max(0, (|temp - 22| - 2) / 8.0))

```

Fungsi ini bernilai 0 pada rentang 20–24°C (zona nyaman) dan meningkat secara linear di luar rentang tersebut, mencapai nilai 1.0 pada suhu di bawah 14°C atau di atas 30°C. Ketidaknyamanan termal mengurangi probabilitas kehadiran dan motivasi mahasiswa.

1.3.5 3.5 Formula IPK Proksi

Pada akhir semester (minggu 14), IPK proksi setiap mahasiswa dihitung sebagai:

$$\text{raw_score} = \text{knowledge_final} \times 0.70 + \text{effective_completion} \times 0.30$$

$$\text{gpa_proxy} = \text{raw_score} \times 4.0$$

di mana *effective_completion* adalah rasio penyelesaian tugas yang disesuaikan dengan penalti keterlambatan dan parameter *strictness* dosen. IPK proksi diklasifikasikan sebagai *gagal (failure)* jika $\text{gpa_proxy} < 2.0$.

Bobot 70/30 antara pengetahuan dan penyelesaian tugas merepresentasikan asumsi umum bahwa nilai akhir seorang mahasiswa lebih didominasi oleh pemahaman materi (ujian akhir, ujian tengah semester) dibandingkan sekadar penyelesaian tugas harian. Serta komponen penyelesaian tugas didasarkan pada temuan Credé dan Kuncel (2008) bahwa kebiasaan belajar merupakan prediktor signifikan kinerja akademik yang bersifat komplementer terhadap kemampuan kognitif.

1.3.6 3.6 Desain Skenario

Sebelas skenario utama dirancang untuk menjawab kelima pertanyaan penelitian. Tabel 3.2 merangkum konfigurasi setiap skenario.

Tabel 3.2: Desain Skenario Eksperimen

Skenario	Mahasiswa	Delay (mgg)	Beban	SES Std	Intervensi	RQ
Baseline (Standar)	30	1	2	0.20	Tidak	Referensi
Kelas Kecil	15	1	2	0.20	Tidak	RQ1
Kelas Besar	60	1	2	0.20	Tidak	RQ1
Umpan Balik Segera	30	0	2	0.20	Tidak	RQ2
Umpan Balik Lambat	30	4	2	0.20	Tidak	RQ2
Beban Ringan	30	1	1	0.20	Tidak	RQ2
Beban Berat	30	1	3	0.20	Tidak	RQ2
Skenario Terburuk	60	4	3	0.20	Tidak	Kasus ekstrem

Skenario	Mahasiswa	Delay (mgg)	Beban	SES Std	Intervensi	RQ
Program Tutoring	30	1	2	0.20	Mgg 7–10	RQ3
Keberagaman SES Tinggi	30	1	2	0.40	Tidak	RQ4
Paket Kebijakan Terbaik	30	0	1	0.20	Mgg 5–12	RQ2+RQ3

Selain 11 skenario di atas, empat skenario lingkungan fisik ditambahkan untuk menjawab RQ5: Kelas Panas (32°C), Kelas Dingin (16°C), Perkuliahan Daring Penuh, dan Perkuliahan Hibrida.

Tabel 3.3 memetakan keterkaitan antara setiap skenario dengan pertanyaan penelitian yang dijawab.

Tabel 3.3: Matriks Skenario x Pertanyaan Penelitian

Skenario	RQ1 (Ukuran Kelas)	RQ2 (Umpan Balik & Beban)	RQ3 (Intervensi)	RQ4 (SES)	RQ5 (Lingkungan)
Baseline (Standar)	Referensi	Referensi	Referensi	Referensi	Referensi
Kelas Kecil (15)	☐				
Kelas Besar (60)	☐				
Umpan Balik Segera (0 mgg)		☐			
Umpan Balik Lambat (4 mgg)		☐			
Beban Ringan (1/mgg)		☐			
Beban Berat (3/mgg)		☐			

Skenario	RQ1 (Ukuran Kelas)	RQ2 (Umpan Balik & Beban)	RQ3 (Intervensi)	RQ4 (SES)	RQ5 (Lingkungan)
Skenario Terburuk (60+3+4)	☐	☐			
Program Tutoring (mgg 7–10)			☐		
Keberagaman SES Tinggi				☐	
Paket Kebijakan Terbaik		☐	☐		
Kelas Panas (32°C)					☐
Kelas Dingin (16°C)					☐
Daring Penuh					☐
Hibrida					☐

1.3.7 3.7 Reprodusibilitas

Setiap simulasi menggunakan `numpy.random.default_rng(seed)` dengan nilai *seed* yang tersimpan bersama konfigurasi. *Seed* yang sama selalu menghasilkan keluaran yang identik (*deterministic reproducibility*). Berkas `config.json` disimpan bersama setiap hasil eksperimen, memungkinkan replikasi penuh.

1.3.8 3.8 Analisis Sensitivitas *One-at-a-Time* (OAT)

Untuk mengidentifikasi parameter kebijakan mana yang paling berpengaruh, dilakukan analisis sensitivitas *one-at-a-time* (OAT). Setiap parameter diubah dari nilai rendah ke nilai tinggi sementara semua parameter lain dipertahankan pada nilai baseline. Selisih metrik (Δ metric) dihitung relatif terhadap baseline, dan parameter diurutkan berdasarkan $|\Delta|$ terbesar.

Delapan parameter yang diuji adalah: ukuran kelas, keterlambatan umpan balik, beban tugas, efektivitas pengajaran, rerata SES, suhu ruangan, pembelajaran teman sebaya, dan mode kelas. Setiap konfigurasi dijalankan sebanyak `n_runs = 3 seed` untuk mengurangi *noise* stokastik.

1.3.9 3.9 Validasi Model

Model divalidasi melalui empat pendekatan:

1. **Validitas Wajah (*Face Validity*):** Arah semua efek diperiksa terhadap prediksi literatur (Hattie 2008, Shute 2008, ASHRAE 55). Kelas besar harus menghasilkan IPK lebih rendah; umpan balik lambat harus meningkatkan stres; suhu ekstrem harus mengurangi motivasi.
2. **Uji Determinisme:** Simulasi dijalankan dua kali dengan *seed* yang sama. Keluaran harus identik secara bit-per-bit. Uji ini memverifikasi tidak ada sumber non-determinisme tersembunyi.
3. **Uji Klem (*Clamp Test*):** Semua simulasi dijalankan dengan 100 *seed* acak. Semua variabel status harus tetap berada dalam rentang valid ($[0,1]$ untuk knowledge, stress, motivation, dll.) sepanjang 14 minggu.
4. **Uji Konvergensi:** Simulasi baseline dijalankan dengan $N = 10, 15, 20, 30, 45, 60, 90, 120$ mahasiswa, masing-masing 10 *seed*. IPK rata-rata beserta interval kepercayaan 95% (CI) dihitung untuk setiap N . Konvergensi tercapai jika CI menyempit seiring bertambahnya N , mengonfirmasi bahwa $N = 30$ cukup untuk estimasi yang stabil.

1.3.10 3.10 Asumsi dan Keterbatasan Model

Beberapa asumsi penting yang mendasari model ini, yang juga merupakan keterbatasan yang perlu diperhatikan dalam interpretasi hasil:

1. **Parameter bersifat ilustratif.** Nilai-nilai seperti `base_learning_rate = 0.28` atau `topic_dependency_strength = 0.40` dipilih agar menghasilkan pola kualitatif yang masuk akal, bukan dikalibrasi dari data empiris.
2. **Model putus studi disederhanakan.** Putus studi dimodelkan menggunakan heuristik stres tinggi berturut-turut, tanpa mempertimbangkan faktor psikososial yang lebih kompleks (Tinto, 1987).
3. **Kelompok belajar statis.** Jaringan pertemanan tidak berkembang secara dinamis selama semester.
4. **Satu mata kuliah, satu dosen.** Beban studi dari mata kuliah lain, kehadiran asisten dosen, atau tim pengajar tidak dimodelkan.
5. **Tekanan eksternal sebagai skalar.** Faktor-faktor seperti pekerjaan paruh waktu atau kewajiban keluarga direpresentasikan hanya sebagai satu parameter `external_pressure`.
6. **Tidak ada umpan balik real-time dari kelas nyata.** Model ini adalah *virtual twin / policy simulator*, bukan *digital twin* dalam arti penuh karena tidak terhubung dengan data LMS aktual (Rasheed et al., 2020).