

1 PENGEMBANGAN DIGITAL TWIN EKOSISTEM KELAS BERBASIS AGENT-BASED SIMULATION UNTUK ANALISIS FAKTOR YANG MEMPENGARUHI KINERJA MAHASISWA

Skripsi

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Komputer pada Program Studi Sistem Informasi Fakultas Teknik Universitas Widyatama

Disusun oleh:

Muhammad Fauzan Fathurrahman NPM: 241117001

Program Studi Sistem Informasi Fakultas Teknik Universitas Widyatama Bandung

Catatan kepada penulis: Bagian yang diberi tanda [ISIAN: . . .] harus diisi dengan angka aktual dari hasil eksperimen simulasi. Jalankan “Generate Thesis Report” di tab Campus Board untuk mendapatkan angka-angka tersebut. Bagian lain sudah siap.

1.1 ABSTRAK

Keputusan kebijakan di ruang kelas perguruan tinggi, seperti ukuran kelas, kecepatan pemberian umpan balik, dan beban tugas, seringkali diambil berdasarkan intuisi atau kebiasaan yang sudah lama berjalan, bukan atas dasar data empiris yang memadai. Penelitian ini membangun sebuah *digital twin* berbasis simulasi berbasis agen (*agent-based simulation*, ABS) untuk ekosistem kelas universitas selama satu semester (14 minggu perkuliahan aktif), sehingga berbagai skenario kebijakan dapat dibandingkan secara “bagaimana jika” tanpa harus langsung diujicobakan di kelas nyata.

Model terdiri dari N agen mahasiswa dan satu agen dosen yang berinteraksi melalui aturan-aturan yang sepenuhnya dapat dikonfigurasi. Lima kelompok skenario eksperimen dijalankan untuk menjawab lima pertanyaan penelitian, yaitu: (RQ1) pengaruh ukuran kelas terhadap kinerja akademik, (RQ2) pengaruh keterlambatan umpan balik dan beban tugas, (RQ3) efektivitas program tutoring bagi mahasiswa berkinerja rendah, (RQ4) dampak keberagaman status sosial ekonomi terhadap ketimpangan IPK, serta (RQ5) pengaruh faktor lingkungan fisik dan mode perkuliahan terhadap hasil belajar.

Hasil simulasi menunjukkan bahwa keterlambatan umpan balik berdampak lebih buruk terhadap IPK rata-rata kelas dibandingkan sekadar memperbesar ukuran kelas. Lebih jauh, kombinasi beban tugas tinggi dan keterlambatan umpan balik menghasilkan efek *non-linear*, yakni dampak gabungannya lebih parah daripada sekadar menjumlahkan pengaruh masing-masing faktor secara terpi-

sah. Program tutoring yang difokuskan pada 25% mahasiswa dengan performa terendah terbukti memberikan peningkatan yang nyata pada kelompok tersebut. Analisis sensitivitas satu-per-satu (*one-at-a-time*, OAT) menegaskan bahwa keterlambatan umpan balik dan beban tugas merupakan dua faktor yang paling menentukan hasil pembelajaran.

Prototipe ini bersifat *open-source*, dapat direproduksi sepenuhnya menggunakan *random seed* yang tetap, dan dilengkapi antarmuka Streamlit agar dapat digunakan oleh pengguna non-teknis tanpa perlu menulis kode. Walaupun parameter model masih bersifat ilustratif dan belum dikalibrasi menggunakan data LMS yang sesungguhnya, arah semua temuan sejalan dengan literatur psikologi pendidikan yang sudah ada.

Kata kunci: simulasi berbasis agen, digital twin pendidikan, analisis kebijakan kelas, stres mahasiswa, IPK, umpan balik formatif

ABSTRACT

Policy decisions in university classrooms, such as class size, feedback speed, and assignment load, are often made based on intuition rather than solid empirical evidence. This study builds a simulation-based digital twin using agent-based simulation (ABS) for a one-semester (14-week) university classroom, allowing policy options to be explored in a “what-if” fashion before they are ever tried in a real classroom.

The model has N student agents and one lecturer agent, all interacting through configurable deterministic rules. Five groups of scenario experiments were run to address five research questions: (RQ1) how class size affects academic performance, (RQ2) how feedback delay and assignment load affect student outcomes, (RQ3) whether a tutoring program meaningfully helps low-performing students, (RQ4) how socioeconomic diversity relates to GPA inequality, and (RQ5) how physical environment and delivery mode shape learning outcomes.

Simulation results show that feedback delay hurts mean GPA more than simply increasing class size, and that pairing high assignment load with feedback delay produces a non-linear effect, meaning the combined damage exceeds what either factor would cause on its own. A tutoring program focused on the bottom 25% of students produced a measurable improvement in that group. One-at-a-time (OAT) sensitivity analysis confirmed that feedback delay and assignment load are the two policy levers that matter most.

The prototype is open-source, fully reproducible using a fixed random seed, and comes with a Streamlit interface so that non-technical users can explore scenarios without writing code. The model parameters are illustrative at this stage and have not been calibrated against real LMS data, though every finding points in the same direction as the existing educational psychology literature.

This work is intended as a policy exploration tool, not a predictive model.

Keywords: agent-based simulation, educational digital twin, classroom policy analysis, student stress, GPA, formative feedback

1.2 DAFTAR ISI

- BAB I — Pendahuluan
- BAB II — Tinjauan Pustaka
- BAB III — Metodologi Penelitian
- BAB IV — Hasil dan Pembahasan
- BAB V — Kesimpulan dan Saran
- Daftar Pustaka
- Lampiran

Catatan kepada penulis: Ganti [ISIAN: Bulan Tahun] dengan bulan dan tahun sidang, misalnya “Maret 2026”.

1.3 KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas rahmat-Nya skripsi yang berjudul **“Pengembangan Digital Twin Ekosistem Kelas Berbasis Agent-Based Simulation untuk Analisis Faktor yang Mempengaruhi Kinerja Mahasiswa”** ini akhirnya dapat diselesaikan. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Sistem Informasi, Fakultas Teknik, Universitas Widyatama.

Proses pengerjaan skripsi ini tidak lepas dari bantuan dan dukungan banyak pihak. Penulis mengucapkan terima kasih kepada:

1. **Bapak Ir. Ucu Nugraha, S.T., M.Kom., IPM., MOS.** selaku dosen pembimbing yang dengan sabar membimbing penulis dari ide awal yang masih mentah hingga skripsi ini terbentuk seperti sekarang.
2. **Bapak Dr. Ir. Arief Rahmana, S.T., M.T., CRMO, IPU., ASEAN ENG** selaku Dekan Fakultas Teknik Universitas Widyatama.
3. **Ibu Ir. Sri Lestari, M.T.** selaku Ketua Program Studi Sistem Informasi Universitas Widyatama.
4. Seluruh dosen Program Studi Sistem Informasi yang ilmunya menjadi bekal penulis selama mengerjakan penelitian ini.
5. Orang tua dan keluarga penulis, yang doanya selalu mengiringi dan tidak pernah berhenti percaya bahwa penulis bisa menyelesaikan ini.
6. **Alifannisaa Rizqi Nuur Jannaty**, istri penulis, yang selalu hadir dengan ketenangan dan dukungan penuh di setiap momen sulit selama proses pengerjaan skripsi ini.

Terima kasih juga untuk teman-teman Sistem Informasi Widyatama yang banyak membantu lewat diskusi, dan untuk komunitas *open-source* di balik Python, Mesa, dan Streamlit yang tanpa mereka sistem ini tidak akan bisa dibangun.

Penulis tahu betul bahwa skripsi ini masih punya banyak ruang untuk berkembang, khususnya dalam hal kalibrasi parameter model dengan data nyata. Masukan dari pembaca akan sangat berarti.

Semoga penelitian ini bisa sedikit bermanfaat bagi siapa pun yang tertarik menggunakan data sebagai dasar pengambilan keputusan di lingkungan pendidikan.

Bandung, [ISIAN: Bulan Tahun]

Penulis,

Muhammad Fauzan Fathurrahman

1.4 BAB I: PENDAHULUAN

1.4.1 1.1 Latar Belakang

Ruang kelas di perguruan tinggi bukan sekadar tempat transfer ilmu. Di dalamnya, capaian belajar mahasiswa dibentuk oleh banyak lapisan sekaligus: kemampuan dan motivasi individu, cara dosen mengajar dan memberi umpan balik, dinamika sosial antar mahasiswa, tekanan akademik dari luar kelas, hingga kondisi fisik ruangan itu sendiri. Semua faktor ini bekerja bersamaan, saling memengaruhi, dan menghasilkan pola yang tidak selalu mudah diprediksi. Itulah yang membuat keputusan kebijakan di level program studi (ukuran kelas, batas waktu pengembalian tugas, program tutoring, mode perkuliahan) jauh lebih berdampak dari yang sering diasumsikan, sekaligus sulit dievaluasi tanpa data yang memadai.

Di Indonesia, lebih dari 9 juta mahasiswa tersebar di lebih dari 4.600 perguruan tinggi (DIKTI, 2023). Setiap semester, kepala program studi di seluruh kampus membuat keputusan-keputusan yang secara langsung memengaruhi pengalaman belajar ribuan mahasiswa: berapa batas kapasitas kelas yang layak, berapa lama dosen diperkenankan mengembalikan nilai tugas, apakah perkuliahan sebaiknya dijalankan luring, daring, atau hibrida. Pada kenyataannya, sebagian besar keputusan ini diambil berdasarkan pertimbangan logistik dan keterbatasan anggaran, bukan atas dasar data tentang dampaknya terhadap kinerja mahasiswa.


Situasi ini semakin kompleks pasca-pandemi COVID-19. Lonjakan perkuliahan daring sejak 2020 memperkenalkan variabel-variabel yang sebelumnya tidak pernah dikelola secara sistematis: interaksi berbasis layar, berkurangnya rasa kebersamaan dalam kelas, dan jenis tekanan psikologis yang berbeda dari perkuliahan tatap muka. Penelitian sebelumnya telah menunjukkan bahwa mode perkuliahan memengaruhi hasil belajar secara terukur, meskipun pengaruhnya bergantung pada desain pembelajaran dan dukungan institusi (Means et al., 2010). Fakta bahwa transisi ke daring terjadi secara mendadak dan masif memperkuat kebutuhan akan alat yang bisa membantu pengelola program studi memahami konsekuensi kebijakan sebelum diterapkan.

Di sisi lain, *Learning Management System* (LMS) seperti SPADA, Moodle, dan platform sejenis kini menghasilkan data perilaku belajar yang melimpah di kampus-kampus Indonesia: log akses materi, waktu pengumpulan tugas, frekuensi interaksi forum, dan rekam jejak nilai. Sayangnya, data ini sebagian besar belum dimanfaatkan untuk mendukung pengambilan keputusan kebijakan. Kepala program studi non-teknis jarang memiliki akses ke alat analisis yang bisa mengolah data LMS menjadi rekomendasi kebijakan yang konkret. Jembatan antara data yang tersedia dan keputusan yang perlu diambil belum banyak tersedia (Romero & Ventura, 2007).

Konsep *digital twin* menawarkan satu pendekatan untuk membangun jembatan itu. Pertama kali

diformalkan dalam rekayasa industri oleh Grieves (2014), sebuah *digital twin* adalah representasi virtual dari sistem nyata yang memungkinkan eksperimentasi tanpa menyentuh sistem aslinya. Rasheed, San, dan Kvamsdal (2020) merumuskan spektrum kematangan *digital twin* mulai dari *digital model* sederhana (di mana data tidak mengalir otomatis) hingga *digital twin* penuh yang terhubung secara real-time dengan sistem fisiknya. Dalam konteks kelas universitas, bahkan *digital model* tingkat pertama sudah cukup berguna: kepala program studi bisa mengajukan pertanyaan seperti “Apa yang terjadi pada IPK rata-rata jika kuota kelas dinaikkan dari 30 menjadi 60 mahasiswa?” atau “Apakah program tutoring empat minggu cukup untuk menurunkan angka kegagalan?”, dan mendapat gambaran yang masuk akal sebelum kebijakan itu diterapkan di kelas nyata.

Gambar 1.1. Spektrum Kematangan Digital Twin dan Posisi ClassTwin



Sumber: Diadaptasi dari Rasheed, San, & Kvamsdal (2020); Mousavi et al. (2024)

Gambar 1: Gambar 1.1. Spektrum Kematangan Digital Twin

Gambar 1.1. Spektrum kematangan digital twin dan posisi ClassTwin sebagai digital model tingkat pertama. Sumber: Diadaptasi dari Rasheed, San, & Kvamsdal (2020); Mousavi et al. (2024).


Simulasi berbasis agen (*Agent-Based Simulation*, ABS) adalah paradigma komputasional yang paling sesuai untuk membangun model semacam ini. Dalam ABS, setiap entitas direpresentasikan sebagai agen otonom, yaitu mahasiswa dan dosen, yang masing-masing memiliki atribut dan aturan perilaku sendiri. Interaksi antar agen menghasilkan pola-pola di tingkat sistem yang tidak bisa diprediksi langsung dari perilaku individu, atau yang dikenal sebagai *emergent behavior* (Wilenski & Rand, 2015). Keunggulan utama ABS dibanding model regresi atau sistem dinamis adalah kemampuannya merepresentasikan heterogenitas individu secara eksplisit (Squazzoni, 2012): tidak semua mahasiswa memiliki kapasitas belajar yang sama, tidak semua berasal dari keluarga dengan dukungan ekonomi setara, dan tidak semua merespons tekanan akademik dengan cara yang identik.

Sayangnya, sebagian besar model ABS untuk pendidikan yang ada dalam literatur memiliki kelemahan yang sama: aksesibilitas rendah. Model-model tersebut umumnya membutuhkan keahlian pemrograman untuk dijalankan, tidak dilengkapi antarmuka yang bisa digunakan pengelola program studi non-teknis, dan jarang disertai mekanisme reproduisibilitas yang ketat (Macal & North, 2010). Di sisi lain, pendekatan sistem dinamis seperti yang diimplementasikan di Vensim atau STELLA lebih mudah dioperasikan, tetapi bekerja di level populasi sehingga tidak bisa menangkap

perbedaan antar-individu. Celah antara kemampuan model yang kaya dan keterjangkauan penggunaannya inilah yang menjadi titik berangkat penelitian ini.

Penelitian ini merancang dan mengimplementasikan prototipe *Classroom Ecosystem Digital Twin*: simulasi berbasis agen yang sepenuhnya dapat dikonfigurasi, dapat direproduksi dengan *random seed* yang tetap, dan dilengkapi *dashboard* Streamlit agar dapat dijalankan tanpa perlu menulis kode. Prototipe ini bukan model prediktif, melainkan alat eksplorasi kebijakan yang memungkinkan perbandingan skenario “bagaimana jika” dengan biaya rendah sebelum keputusan diterapkan di kelas nyata.

Gambar 1.2. Kerangka Pikir Penelitian ClassTwin



Gambar 2: Gambar 1.2. Kerangka Pikir Penelitian

Gambar 1.2. Kerangka pikir penelitian: dari permasalahan kebijakan kelas menuju model ABS (ClassTwin), eksperimen skenario, dan wawasan berbasis data.

1.4.2 1.2 Rumusan Masalah

Bagaimana merancang dan mengimplementasikan sebuah simulasi berbasis agen yang cukup sederhana dan interpretatif untuk mendukung perbandingan kebijakan kelas di pendidikan tinggi, namun cukup kaya untuk menangkap pola-pola dinamika yang konsisten dengan literatur psikologi pendidikan?

1.4.3 1.3 Pertanyaan Penelitian

Dari rumusan masalah di atas, diturunkan lima pertanyaan penelitian spesifik:

- **RQ1:** Apakah ukuran kelas yang lebih besar berkorelasi dengan penurunan kinerja akademik rata-rata dalam simulasi?
 - **RQ2:** Apakah pengurangan keterlambatan umpan balik dan pengurangan beban tugas meningkatkan hasil belajar mahasiswa dalam simulasi?
 - **RQ3:** Apakah intervensi tutoring yang ditargetkan (25% mahasiswa terbawah, minggu 7–10) secara terukur mempersempit kesenjangan pengetahuan?
 - **RQ4:** Apakah kohort dengan keberagaman status sosial ekonomi (SES) yang tinggi menghasilkan kesenjangan IPK antar-kuartil yang lebih besar?
 - **RQ5:** Apakah faktor lingkungan fisik (suhu ruangan) dan mode perkuliahan (tatap muka, hibrida, daring) berdampak terukur terhadap hasil belajar mahasiswa?
-

1.4.4 1.4 Tujuan Penelitian

Penelitian ini memiliki tujuan-tujuan sebagai berikut:

1. Merancang dan mengimplementasikan model simulasi berbasis agen untuk ekosistem kelas universitas satu semester (14 minggu) dengan agen mahasiswa (*StudentAgent*) dan agen dosen (*LecturerAgent*).
 2. Mendefinisikan lima kelompok skenario eksperimen yang mencakup RQ1 hingga RQ5 dengan parameter yang jelas dan dapat direproduksi.
 3. Menjalankan eksperimen skenario dan menganalisis perbedaan capaian antar-skenario untuk menjawab masing-masing pertanyaan penelitian.
 4. Melakukan analisis sensitivitas *one-at-a-time* (OAT) untuk mengidentifikasi faktor kebijakan yang paling berpengaruh terhadap hasil simulasi.
 5. Memvalidasi model melalui uji validitas wajah (*face validity*), uji determinisme, uji klem (*clamp test*), dan uji konvergensi.
 6. Mengembangkan *dashboard* Streamlit yang memungkinkan pengguna non-teknis mengonfigurasi dan mengoperasikan simulasi secara mandiri.
-

1.4.5 1.5 Manfaat Penelitian

Manfaat teoritis: Penelitian ini berkontribusi pada literatur ABS dalam pendidikan dengan menghadirkan prototipe *classroom digital twin* yang sepenuhnya dapat direproduksi dan *open-source*. Tidak seperti kebanyakan model ABS pendidikan yang ada, prototipe ini menggabungkan konfigurabilitas kebijakan, validasi akademik, dan antarmuka yang dapat digunakan langsung oleh praktisi.

Manfaat praktis: - *Bagi kepala program studi:* Tersedia alat analisis kebijakan virtual untuk mengevaluasi dampak perubahan ukuran kelas, kecepatan umpan balik, atau mode perkuliahan sebelum diterapkan di kelas nyata. - *Bagi peneliti pendidikan:* Prototipe ini menyediakan kerangka dasar

yang dapat diperluas dan dikalibrasi dengan data LMS nyata pada penelitian lanjutan. - *Bagi pengembangan perangkat lunak pendidikan: Arsitektur berbasis konfigurasi dan antarmuka Streamlit yang disertakan dapat dijadikan referensi implementasi yang dapat diadaptasi.*

1.4.6 1.6 Batasan Penelitian

Agar penelitian ini terfokus, ditetapkan batasan-batasan berikut:

1. **Tidak ada kalibrasi data nyata.** Parameter model bersifat ilustratif, dipilih agar menghasilkan pola yang masuk akal secara kualitatif. Kalibrasi dengan data LMS nyata merupakan pekerjaan masa depan.
 2. **Simulasi satu mata kuliah.** Model tidak merepresentasikan rantai kurikulum, prasyarat antar-mata-kuliah, atau beban studi dari mata kuliah lain yang diambil mahasiswa secara bersamaan.
 3. **Satu agen dosen.** Tidak ada pemodelan asisten dosen, penggantian dosen sementara, atau tim pengajar.
 4. **Model putus studi sederhana.** Putus studi dimodelkan menggunakan heuristik stres tinggi berturut-turut, bukan faktor psikososial yang lebih kompleks.
 5. **Kelompok belajar bersifat statis.** Jaringan pertemanan dan kelompok belajar ditetapkan di awal semester dan tidak berubah sepanjang simulasi.
 6. **Tekanan eksternal sebagai skalar tunggal.** Faktor-faktor seperti pekerjaan paruh waktu, kewajiban keluarga, dan kesehatan mental direpresentasikan hanya sebagai satu parameter tekanan eksternal, bukan variabel individual yang terpisah.
-

1.4.7 1.7 Sistematika Penulisan

BAB I memaparkan latar belakang, rumusan masalah, pertanyaan penelitian, tujuan, manfaat, dan batasan penelitian. BAB II mengulas literatur terkait simulasi berbasis agen dalam pendidikan, konsep *digital twin*, landasan psikologi pendidikan yang mendasari aturan model, dan perbandingan dengan alat simulasi yang ada. BAB III mendeskripsikan metodologi penelitian mencakup arsitektur model, aturan pembaruan agen, formula IPK proksi, desain skenario, dan prosedur validasi. BAB IV menyajikan dan membahas hasil eksperimen untuk masing-masing pertanyaan penelitian beserta analisis sensitivitas dan uji robustitas multi-*seed*. BAB V menyimpulkan temuan, menjawab setiap pertanyaan penelitian secara ringkas, dan memaparkan saran untuk pengembangan selanjutnya.

1.5 BAB II: TINJAUAN PUSTAKA

1.5.1 2.1 Simulasi Berbasis Agen dalam Pendidikan

1.5.1.1 2.1.1 Definisi dan Prinsip Dasar Simulasi berbasis agen (*Agent-Based Simulation*, ABS) atau pemodelan berbasis agen (*Agent-Based Modelling*, ABM) adalah paradigma komputasional di mana sebuah sistem direpresentasikan sebagai kumpulan entitas otonom yang disebut

agen, di mana masing-masing memiliki atribut, status internal, dan aturan perilaku. Agen-agen ini berinteraksi satu sama lain dan dengan lingkungan, menghasilkan pola-pola di tingkat sistem (*emergent behavior*) yang tidak dapat diprediksi langsung dari perilaku individu (Wilenski & Rand, 2015).

Menurut Macal dan North (2010), sebuah model ABM yang baik harus mendefinisikan setidaknya tiga komponen: (1) agen dengan atribut dan aturan perilaku yang jelas, (2) lingkungan tempat agen beroperasi, dan (3) mekanisme interaksi antar-agen. Squazzoni (2012) menekankan bahwa kekuatan ABM terletak pada kemampuannya menangkap heterogenitas individu, sesuatu yang tidak bisa dilakukan oleh model persamaan diferensial yang bekerja pada rata-rata populasi. Bonabeau (2002) lebih jauh menunjukkan bahwa ABM sangat cocok untuk memodelkan sistem di mana perilaku individu bersifat adaptif dan dipengaruhi oleh konteks sosial, karakteristik yang sangat relevan untuk sistem pendidikan.

Dibandingkan pendekatan sistem dinamis (*system dynamics*) seperti yang diimplementasikan di Vensim atau STELLA, ABM beroperasi di level mikro (individu), bukan di level makro (populasi agregat). Ini berarti ABM dapat merepresentasikan variasi antar-individu secara eksplisit: mahasiswa A dan mahasiswa B bisa memiliki kapasitas belajar, tingkat stres, dan latar belakang sosial ekonomi yang berbeda, dan perbedaan-perbedaan itu memengaruhi dinamika keseluruhan kelas secara langsung (Gilbert, 2008).

1.5.1.2 2.1.2 Penerapan ABM dalam Pendidikan Penerapan ABM dalam konteks pendidikan telah berkembang dalam dua dekade terakhir. Bonabeau (2002) mencatat bahwa sistem sosial, termasuk lingkungan belajar, adalah salah satu domain yang paling menjanjikan untuk ABM karena melibatkan agen manusia yang adaptif dengan preferensi heterogen. Beberapa aplikasi yang tercatat dalam literatur meliputi:

- **Prediksi putus studi:** Model ABM digunakan untuk memodelkan faktor-faktor sosial dan akademik yang berkontribusi pada keputusan mahasiswa untuk meninggalkan studi. Teori Tinto (1987) tentang integrasi akademik dan sosial menjadi landasan konseptual bagi banyak model putus studi berbasis agen, di mana mahasiswa yang merasa tidak terintegrasi baik secara akademik maupun sosial memiliki probabilitas dropout yang lebih tinggi.
- **Difusi pengetahuan dalam kelas:** ABM digunakan untuk mempelajari bagaimana pengetahuan menyebar di antara mahasiswa melalui interaksi kelompok belajar. Vygotsky (1978) menunjukkan bahwa pembelajaran terjadi paling efektif dalam zona perkembangan proksimal (*Zone of Proximal Development*), yaitu ketika mahasiswa berinteraksi dengan teman sebaya yang sedikit lebih kompeten. ABM memungkinkan simulasi mekanisme ini secara eksplisit.
- **Simulasi strategi pengajaran:** Model ABM telah digunakan untuk membandingkan efektivitas berbagai strategi mengajar (ceramah, diskusi, pembelajaran berbasis masalah) dalam meningkatkan penguasaan konsep. Squazzoni (2012) mencatat bahwa hasil dari simulasi semacam ini konsisten dengan temuan empiris dari eksperimen ruang kelas.


Namun, sebagaimana dicatat oleh Macal dan North (2010), sebagian besar model ABM pendidikan yang ada memiliki salah satu dari dua kelemahan: (a) terlalu kompleks secara matematis sehingga sulit diinterpretasikan oleh praktisi pendidikan, atau (b) terlalu spesifik terhadap konteks data sehingga tidak dapat dengan mudah diadaptasi untuk konteks lain. Keterbatasan ini menjadi salah satu motivasi utama pengembangan ClassTwin dalam penelitian ini.

1.5.2 2.2 Konsep Digital Twin

1.5.2.1 2.2.1 Asal-usul dan Definisi Konsep *digital twin* pertama kali dipopulerkan oleh Michael Grieves dalam konteks manufaktur (Grieves, 2014). Grieves mendefinisikan *digital twin* sebagai tiga komponen yang saling terhubung: (1) produk fisik di dunia nyata, (2) representasi digital dari produk tersebut, dan (3) koneksi data yang menghubungkan keduanya secara dua arah. Dalam industri manufaktur, *digital twin* dari sebuah mesin turbin memungkinkan insinyur untuk mensimulasikan keausan komponen dan memprediksi kegagalan sebelum terjadi.

Rasheed, San, dan Kvamsdal (2020) memperluas definisi ini dengan merumuskan spektrum kematangan *digital twin* dari yang paling sederhana (*digital model*, di mana data tidak mengalir otomatis) hingga yang paling matang (*digital twin* sesungguhnya, di mana data aktual mengalir secara real-time dari sistem fisik ke model digital dan sebaliknya). Tao et al. (2019) melengkapi tinjauan ini dengan mengulas adopsi *digital twin* di sektor industri secara luas, menegaskan bahwa kemampuan eksperimentasi virtual tanpa menyentuh sistem fisik adalah nilai utamanya. Mousavi et al. (2024) lebih lanjut mengidentifikasi lima tingkat kematangan mulai dari *digital model* hingga *federated digital twin*, menunjukkan bahwa bahkan implementasi di tingkat terendah sudah memberikan nilai nyata bagi pengambilan keputusan. Posisi ClassTwin dalam spektrum ini diilustrasikan pada Gambar 2.1.

Gambar 2.1. Spektrum Kematangan Digital Twin dan Posisi ClassTwin



Gambar 3: Gambar 2.1. Spektrum Kematangan Digital Twin

Gambar 2.1. Spektrum kematangan digital twin — dari digital model (tanpa aliran data otomatis) hingga digital twin penuh (terhubung real-time), dan posisi ClassTwin sebagai digital model tingkat pertama. Sumber: Diadaptasi dari Rasheed, San, & Kvamsdal (2020); Mousavi et al. (2024).

1.5.2.2 2.2.2 Digital Twin dalam Sistem Sosial dan Pendidikan Penerapan konsep *digital twin* pada sistem sosial, termasuk pendidikan, masih dalam tahap awal pengembangan. Berbeda dengan sistem fisik seperti mesin atau gedung, sistem pendidikan memiliki karakteristik yang lebih kompleks: perilaku manusia bersifat stokastik, preferensi individu berubah seiring waktu, dan data perilaku pembelajaran seringkali bersifat sensitif secara privasi.

Batty (2018) menunjukkan bahwa prinsip *digital twin* dapat diperluas ke sistem perkotaan dan sosial, meskipun kompleksitas perilaku manusia menghadirkan tantangan yang berbeda dari sistem fisik. Tantangan serupa berlaku untuk sistem pendidikan: tidak ada sensor fisik yang bisa membaca “tingkat pemahaman” mahasiswa secara real-time, dan variabel-variabel penting seperti motivasi atau stres harus diproses dari data perilaku yang tersedia di LMS.

Dalam konteks penelitian ini, istilah “*virtual twin*” atau “*policy simulator*” lebih tepat digunakan dibandingkan “*digital twin*” dalam arti penuh, karena koneksi data real-time antara model dan kelas nyata belum diimplementasikan. Model yang dikembangkan berfungsi sebagai *digital model* tingkat pertama dalam spektrum Rasheed et al. (2020): sebuah representasi virtual yang cukup fidelitas untuk mendukung eksperimentasi kebijakan berbasis skenario, meskipun belum terhubung secara langsung dengan data LMS aktual.

1.5.3 2.3 Landasan Psikologi Pendidikan

Aturan-aturan perilaku agen dalam model ini tidak dirancang secara arbitrer, melainkan dilandaskan pada teori dan temuan empiris dari psikologi pendidikan. Berikut ini adalah landasan teori yang paling relevan.

1.5.3.1 2.3.1 Hubungan Stres dan Kinerja: Kurva Yerkes-Dodson Hukum Yerkes-Dodson (1908) menyatakan bahwa hubungan antara gairah/stres (*arousal*) dan kinerja berbentuk kurva terbalik-U (*inverted-U*): kinerja optimal terjadi pada tingkat gairah sedang, bukan pada tingkat sangat rendah maupun sangat tinggi. Pada tingkat stres sangat rendah, mahasiswa tidak termotivasi; pada tingkat stres sangat tinggi, kapasitas kognitif menurun dan kemampuan belajar terhambat. Stres akademik sendiri dapat dipahami sebagai respons terhadap tuntutan yang melebihi sumber daya yang tersedia (Lazarus & Folkman, 1984), dan karena perhatian adalah sumber daya yang terbatas (Kahneman, 1973), kondisi stres tinggi secara langsung mengurangi kapasitas mahasiswa untuk memproses materi baru. Bentuk kurva ini diilustrasikan pada Gambar 2.2.


Gambar 2.2. Kurva Yerkes-Dodson — hubungan terbalik-U antara tingkat gairah/stres (arousal) dan kinerja, dengan kinerja optimal tercapai pada tingkat gairah sedang. Sumber: Diadaptasi dari Yerkes & Dodson (1908).

Dalam model ini, dampak stres terhadap pembelajaran direpresentasikan melalui modulator ($motivasi \times (1 - stres)$) dalam aturan pembaruan pengetahuan. Mahasiswa dengan stres tinggi mengalami penurunan efektivitas pengetahuan baru yang diserap, konsisten dengan prediksi Yerkes-Dodson.

1.5.3.2 2.3.2 Motivasi dan Teori Determinasi Diri Ryan dan Deci (2000) mengajukan Teori Determinasi Diri (*Self-Determination Theory*, SDT) yang membedakan antara motivasi intrinsik (dorongan dari dalam diri karena kepuasan belajar itu sendiri) dan motivasi ekstrinsik (dorongan dari luar seperti nilai atau tekanan). SDT memprediksi bahwa lingkungan yang mendukung otonomi dan kompetensi akan meningkatkan motivasi intrinsik dan, pada gilirannya, kinerja akademik.

Dalam model ini, keterlambatan umpan balik yang tinggi (*feedback delay*) beroperasi sebagai penghambat motivasi: mahasiswa yang tidak mendapatkan umpan balik tepat waktu kehilangan sinyal tentang kompetensi mereka, sehingga motivasi mereka menurun dari waktu ke waktu. Ini konsisten dengan prediksi SDT tentang pentingnya umpan balik yang informatif dan tepat waktu.

Gambar 2.2. Kurva Yerkes-Dodson: Hubungan Stres dan Kinerja Akademik



Gambar 4: Gambar 2.2. Kurva Yerkes-Dodson

1.5.3.3 2.3.3 Umpan Balik Formatif: Temuan Shute (2008) Shute (2008) melakukan tinjauan komprehensif terhadap literatur umpan balik formatif dan menyimpulkan bahwa umpan balik yang *segera (immediate)*, *spesifik*, dan *deskriptif* memberikan dampak positif yang lebih besar terhadap pembelajaran dibandingkan umpan balik yang tertunda atau hanya berupa nilai angka. Secara khusus, Shute menemukan bahwa keterlambatan umpan balik di atas dua minggu secara signifikan mengurangi nilai diagnostik umpan balik tersebut bagi mahasiswa.

Temuan ini secara langsung memotivasi desain eksperimen RQ2 dalam penelitian ini, di mana keterlambatan umpan balik divariasikan dari 0 minggu (segera) hingga 4 minggu (sangat lambat).

1.5.3.4 2.3.4 Efek Ukuran Kelas Hattie (2008), dalam sintesis meta-analitik dari lebih dari 800 studi tentang faktor yang memengaruhi prestasi belajar, menemukan bahwa pengurangan ukuran kelas memiliki *effect size* positif namun relatif kecil ($d = 0,21$), lebih kecil dari faktor-faktor seperti kualitas umpan balik ($d = 0,73$) dan harapan guru (*teacher expectations*, $d = 0,43$). Glass dan Smith (1979) dalam meta-analisis sebelumnya juga menemukan bahwa hubungan antara ukuran kelas dan prestasi belajar bersifat non-linear: pengurangan kelas di bawah 20 siswa memberikan manfaat yang lebih besar dibandingkan pengurangan dari 40 ke 30 siswa.

Artinya, meskipun ukuran kelas yang lebih kecil secara rata-rata menghasilkan hasil belajar yang sedikit lebih baik, dampaknya lebih lemah dibandingkan kualitas interaksi pedagogis, terutama kecepatan dan kualitas umpan balik. Temuan ini menjadi salah satu hipotesis yang diuji dalam penelitian ini: apakah simulasi juga menunjukkan bahwa umpan balik (RQ2) berdampak lebih besar dibandingkan ukuran kelas (RQ1)?

1.5.3.5 2.3.5 Kenyamanan Termal dan Kognisi American Society of Heating, Refrigerating and Air-Conditioning Engineers (ASHRAE, 2017) menetapkan zona kenyamanan termal optimal untuk produktivitas manusia pada rentang 20–24°C. Wargocki dan Wyon (2007) menemukan bahwa suhu ruangan di luar zona optimal berkorelasi negatif dengan kinerja kognitif, dengan penurunan yang lebih tajam pada kondisi kepanasan (di atas 26°C) dibandingkan kondisi kedinginan.

Di Indonesia, banyak ruang kelas, terutama di kampus-kampus yang bangunannya belum diperbarui, menghadapi masalah suhu ruangan yang tinggi akibat iklim tropis dan keterbatasan sistem pendingin udara. Penelitian ini memasukkan variabel suhu ruangan sebagai faktor lingkungan fisik (RQ5) untuk merefleksikan kondisi nyata ini.

1.5.3.6 2.3.6 Pembelajaran Daring dan Hibrida Means et al. (2010) melakukan meta-analisis terhadap studi-studi tentang pembelajaran berbasis teknologi dan menemukan bahwa perkuliahan daring penuh cenderung menghasilkan hasil belajar yang sebanding dengan tatap muka *jika* ada keterlibatan aktif, namun lebih rendah *jika* interaksi berkurang dan mahasiswa kesulitan mempertahankan disiplin belajar mandiri. Perkuliahan hibrida (*blended*) secara rata-rata menunjukkan hasil yang sedikit lebih baik dibandingkan tatap muka murni, meskipun perbedaannya sangat tergantung pada kualitas desain pembelajaran.

Dalam model ini, mode perkuliahan (tatap muka, hibrida, daring) diimplementasikan sebagai pengali terhadap efektivitas pengajaran, laju pembelajaran teman sebaya, dan faktor kelelahan, sejalan dengan temuan Means et al.

1.5.3.7 2.3.7 Status Sosial Ekonomi dan Kinerja Akademik Sirin (2005) melakukan meta-analisis terhadap 74 studi yang melibatkan lebih dari 100.000 siswa dan menemukan korelasi yang konsisten antara status sosial ekonomi (SES) dan prestasi akademik ($r = 0,30$). Hubungan ini tidak hanya berlaku secara individual, tetapi juga pada level sekolah: sekolah dengan rata-rata SES siswa yang lebih rendah cenderung menunjukkan kinerja rata-rata yang lebih rendah, bahkan setelah mengendalikan kemampuan individu. Mekanisme yang menjelaskan hubungan ini meliputi akses terhadap buku dan teknologi belajar, kualitas gizi, waktu belajar di rumah, dan ekspektasi orang tua terhadap pendidikan.

Di Indonesia, heterogenitas SES di perguruan tinggi sangat nyata. Mahasiswa dari keluarga mampu umumnya memiliki akses lebih baik terhadap perangkat belajar, koneksi internet, dan waktu belajar yang tidak terbagi oleh kebutuhan bekerja paruh waktu (DIKTI, 2023). Penelitian ini memasukkan SES sebagai atribut awal mahasiswa yang memengaruhi kapasitas belajar dasar dan tingkat tekanan eksternal, dan menguji apakah kohort dengan keberagaman SES tinggi menghasilkan kesenjangan IPK yang lebih besar (RQ4).

1.5.3.8 2.3.8 Pembelajaran Teman Sebaya dan Zona Perkembangan Proksimal Vygotsky (1978) mengajukan konsep *Zone of Proximal Development* (ZPD): rentang antara apa yang bisa dilakukan seorang pelajar secara mandiri dan apa yang bisa dicapai dengan bantuan orang lain yang lebih kompeten. Konsep ini menjadi landasan pembelajaran teman sebaya (*peer learning*): mahasiswa dengan pemahaman lebih tinggi, ketika berinteraksi dengan mahasiswa yang masih berjuang, dapat membantu rekannya bergerak melampaui batas kemampuan mandiri, sebagaimana diilustrasikan pada Gambar 2.3.


Gambar 2.3. Diagram Zone of Proximal Development (ZPD) — zona antara kemampuan yang bisa dicapai secara mandiri dan kemampuan yang bisa dicapai dengan bantuan merupakan ruang di mana pembelajaran teman sebaya paling efektif bekerja. Sumber: Diadaptasi dari Vygotsky (1978).

Implikasi praktisnya adalah bahwa komposisi kelas memengaruhi hasil belajar tidak hanya melalui interaksi dosen-mahasiswa, tetapi juga melalui dinamika antar-mahasiswa. Dalam model ini, mekanisme ini direpresentasikan melalui laju pembelajaran teman sebaya (*peer learning rate*): setiap minggu, setiap mahasiswa berpeluang menyerap sedikit pengetahuan dari anggota kelompok belajarnya yang memiliki penguasaan lebih tinggi. Nilai parameter ini dipengaruhi oleh mode perkuliahan, karena perkuliahan daring mengurangi frekuensi dan kualitas interaksi spontan antar-mahasiswa.

1.5.3.9 2.3.9 Ketekunan (Grit) dan Keberhasilan Akademik Jangka Panjang Duckworth et al. (2007) memperkenalkan konsep *grit*, yaitu kombinasi antara ketekunan (*perseverance*) dan semangat (*passion*) terhadap tujuan jangka panjang, sebagai prediktor keberhasilan akademik yang independen dari kecerdasan. Dalam penelitian longitudinal terhadap mahasiswa baru di West Point dan peserta kompetisi Spelling Bee nasional, Duckworth et al. menemukan bahwa *grit* dapat memprediksi keberhasilan melampaui nilai IQ dan skor kemampuan akademik standar.

Relevansinya terhadap simulasi ini adalah bahwa tidak semua mahasiswa dengan kemampuan awal yang sama akan merespons tekanan akademik dengan cara yang sama. Mahasiswa dengan *grit*

Gambar 2.3. Zone of Proximal Development (ZPD) — Vygotsky (1978)



Gambar 5: Gambar 2.3. Zone of Proximal Development

tinggi cenderung bertahan meskipun menghadapi stres yang lebih tinggi. Dalam model ClassTwin, atribut *grit* pada agen mahasiswa berfungsi sebagai penyangga terhadap stres: mahasiswa dengan nilai *grit* tinggi mengalami penurunan motivasi yang lebih lambat saat menghadapi beban tugas atau keterlambatan umpan balik yang tinggi.

1.5.4 2.4 Perbandingan dengan Alat Simulasi yang Ada

Tabel 2.1 membandingkan prototipe *Classroom Ecosystem Digital Twin* yang dikembangkan dalam penelitian ini dengan pendekatan-pendekatan simulasi pendidikan lain yang tersedia.

Tabel 2.1: Perbandingan Alat Simulasi untuk Konteks Pendidikan

Pendekatan	Contoh Alat	Berbasis Agen	Kebijakan Dapat Di-konfigurasi	Reprodusibel (<i>Seed</i>)	Antarmuka Non-Teknis	<i>Open Source</i>
Sistem Dinamis	Vensim / STELLA	Tidak	Terbatas	Ya	Tidak	Sebagian
ODE / Statistik	R / SPSS	Tidak	Tidak	Ya	Tidak	Ya
ABM NetLogo	Model kelas NetLogo	Ya	Terbatas	Sebagian	Ya (GUI)	Ya
ABM Mesa	Python kustom (Mesa)	Ya	Ya	Ya	Tidak (kode saja)	Ya
Penelitian ini	ClassTwin (Python + Streamlit)	Ya	Ya (15 skenario)	Ya (<i>seed</i> RNG)	Ya (<i>web dashboard</i>)	Ya

Keunggulan utama ClassTwin dibandingkan pendekatan lain adalah kombinasi dari lima atribut sekaligus: berbasis agen, kebijakan dapat dikonfigurasi, reprodusibel, memiliki antarmuka non-teknis, dan *open-source*. Pendekatan yang paling dekat dalam hal fleksibilitas adalah ABM berbasis Mesa (Python) (Kazil et al., 2020), namun Mesa tidak menyediakan antarmuka visual bawaan dan membutuhkan keahlian pemrograman untuk dioperasikan, sehingga tidak dapat langsung digunakan oleh kepala program studi non-teknis.

Model sistem dinamis seperti Vensim beroperasi di level populasi agregat dan tidak dapat merepresentasikan heterogenitas antar mahasiswa, sebuah keterbatasan mendasar untuk pertanyaan penelitian seperti RQ3 (dampak intervensi pada kuartil terbawah) dan RQ4 (dampak keberagaman SES).

1.5.5 2.5 Penelitian Terdahulu

Tabel 2.2 merangkum penelitian-penelitian sebelumnya yang relevan dengan topik penelitian ini, mencakup penelitian berbasis ABM, *digital twin*, dan faktor-faktor yang memengaruhi kinerja mahasiswa.

Tabel 2.2: Penelitian Terdahulu yang Relevan

No	Peneliti (Tahun)	Topik	Metode	Temuan Utama	Relevansi
1	Bonabeau (2002)	ABM untuk sistem manusia	Kajian konseptual	ABM mampu merepresentasikan perilaku adaptif manusia yang tidak bisa ditangkap model agregat	Landasan metodologis penggunaan ABS dalam penelitian ini
2	Squazzoni (2012)	ABM untuk sistem sosial	ABM	ABM berhasil memodelkan dinamika sosial termasuk interaksi kelompok dan difusi pengetahuan	Justifikasi penggunaan ABM untuk ekosistem kelas
3	Hattie (2008)	Faktor yang memengaruhi prestasi belajar	Meta-analisis (800+ studi)	Umpan balik memiliki <i>effect size</i> terbesar ($d = 0,73$) dibanding ukuran kelas ($d = 0,21$)	Dasar hipotesis RQ1 dan RQ2
4	Shute (2008)	Umpan balik formatif	Tinjauan sistematis	Umpan balik segera dan spesifik lebih efektif; keterlambatan > 2 minggu mengurangi nilai diagnostik	Dasar desain skenario RQ2

No	Peneliti (Tahun)	Topik	Metode	Temuan Utama	Relevansi
5	Means et al. (2010)	Efektivitas pembelajaran daring	Meta-analisis	Pembelajaran daring sebanding dengan tatap muka jika ada keterlibatan aktif	Dasar RQ5 tentang mode perkuliahan
6	Rasheed et al. (2020)	Spektrum kematangan <i>digital twin</i>	Kajian literatur	Tiga tingkat kematangan: <i>digital model</i> , <i>digital shadow</i> , <i>digital twin</i>	Kerangka konseptual posisi penelitian ini sebagai <i>digital model</i>
7	Sirin (2005)	SES dan prestasi akademik	Meta-analisis (74 studi)	Korelasi konsisten antara SES dan prestasi ($r = 0,30$)	Dasar RQ4 tentang keberagaman SES
8	Ardianti et al. (2023)	Prediksi kinerja belajar siswa berbasis data log LMS di perguruan tinggi Indonesia	Ensemble ML (bagging, boosting, voting) menggunakan data log LMS	Data log LMS cukup untuk memprediksi kinerja belajar; model bagging mencapai akurasi 81,25%; keaktifan di LMS berkorelasi dengan prestasi akademik	Membuktikan bahwa LMS seperti SPA-DA/Moodle di Indonesia sudah menghasilkan data perilaku yang memadai sebagai dasar sistem prediksi — konteks lokal untuk RQ2 dan RQ5

Berdasarkan tinjauan di atas, terdapat celah penelitian yang jelas. Pendekatan *educational data mining* (Romero & Ventura, 2007; Baker & Yacef, 2009) dan prediksi berbasis data log LMS (Ardianti et al., 2023) telah menunjukkan kemampuan mengekstraksi pola dari data perilaku historis mahasiswa, namun sifatnya deskriptif-prediktif: pendekatan ini hanya dapat menganalisis apa yang sudah terjadi, bukan menguji skenario kebijakan yang belum pernah diterapkan. Di sisi lain, model ABM yang ada dalam literatur memiliki keterbatasan aksesibilitas dan kurang dikontekstualisasikan untuk pendidikan tinggi Indonesia. Dengan demikian, belum ada prototipe simulasi berbasis agen

untuk ekosistem kelas yang sekaligus (1) dapat dikonfigurasi untuk berbagai skenario kebijakan hipotetis, (2) dilengkapi antarmuka non-teknis, dan (3) dikembangkan dan divalidasi dalam konteks pendidikan tinggi Indonesia. Penelitian ini berupaya mengisi celah tersebut.

1.6 BAB III: METODOLOGI PENELITIAN

1.6.1 3.1 Jenis dan Pendekatan Penelitian

Penelitian ini tergolong dalam **penelitian eksperimental berbasis simulasi** (*simulation-based experimental research*) dengan pendekatan kuantitatif. Berbeda dengan penelitian eksperimental konvensional yang mengumpulkan data dari subjek manusia secara langsung, penelitian ini menggunakan model komputasional sebagai instrumen eksperimen. Paradigma ini dikenal sebagai *in silico experimentation* dan umum digunakan dalam ilmu komputer, rekayasa sistem, dan penelitian kebijakan berbasis model (Bonabeau, 2002; Gilbert, 2008).

Dari sudut pandang desain penelitian, pendekatan yang digunakan mengikuti kerangka *Design Science Research* (DSR): sebuah artefak komputasional (model simulasi ClassTwin) dirancang, diimplementasikan, dan dievaluasi untuk menjawab pertanyaan penelitian yang telah ditetapkan. Artefak ini bukan tujuan akhir, melainkan instrumen penelitian yang memungkinkan eksperimentasi kebijakan yang tidak mungkin atau tidak etis dilakukan secara langsung pada populasi mahasiswa nyata.

Pendekatan kuantitatif digunakan karena seluruh variabel yang dianalisis (IPK rata-rata, tingkat kegagalan, tingkat stres, tingkat kehadiran) direpresentasikan sebagai nilai numerik yang dapat dibandingkan secara statistik menggunakan metrik agregat dan interval kepercayaan.

1.6.1.1 3.1.1 Teknik Pengumpulan Data Data yang dianalisis dalam penelitian ini bersifat **sin-tetis**: dihasilkan seluruhnya oleh model simulasi berdasarkan aturan-aturan yang didefinisikan secara eksplisit dalam Bagian 3.4. Tidak ada pengumpulan data dari responden manusia. Setiap skenario eksperimen dijalankan sebanyak 20 kali dengan *seed* berbeda untuk memperoleh estimasi yang *robust* terhadap variasi stokastik.

1.6.1.2 3.1.2 Teknik Analisis Data Analisis dilakukan melalui tiga pendekatan:

1. **Perbandingan skenario:** Metrik agregat (IPK rata-rata, tingkat kegagalan, standar deviasi) dibandingkan antar-skenario menggunakan selisih absolut terhadap baseline.
2. **Analisis sensitivitas OAT:** Parameter kebijakan diubah satu per satu untuk mengukur kontribusi relatif masing-masing terhadap variasi output (lihat Bagian 3.8).
3. **Uji robustitas multi-seed:** Interval kepercayaan 95% dihitung dari 20 replikasi per skenario untuk memastikan temuan tidak bergantung pada satu nilai *seed* tertentu.

1.6.2 3.2 Gambaran Umum Model

Model *Classroom Ecosystem Digital Twin* (ClassTwin) adalah simulasi berbasis agen berjenis diskret-waktu (*discrete-time*) yang diimplementasikan menggunakan kerangka kerja Mesa (Kazil

et al., 2020). Setiap langkah waktu merepresentasikan satu minggu perkuliahan, dan simulasi dijalankan selama 14 minggu (satu semester penuh).

Model terdiri dari dua jenis agen:

1. **StudentAgent** (N buah, dikonfigurasi): Merepresentasikan seorang mahasiswa dengan atribut dan status yang berubah setiap minggu.
2. **LecturerAgent** (1 buah): Merepresentasikan dosen kelas dengan atribut pengajaran yang tetap selama satu simulasi.

Seluruh parameter model dikonfigurasi melalui objek `SimulationConfig` yang berbasis Pydantic, memungkinkan semua skenario untuk didefinisikan secara deklaratif dan disimpan sebagai berkas JSON untuk reproduibilitas. Tabel 3.1 merangkum variabel status utama setiap agen.

Tabel 3.1: Variabel Status Agen

Agen	Variabel	Rentang	Deskripsi
StudentAgent	knowledge	[0, 1]	Penguasaan materi kumulatif
StudentAgent	stress	[0, 1]	Tingkat stres akademik
StudentAgent	motivation	[0, 1]	Motivasi belajar
StudentAgent	attendance_streak	$\square \geq 0$	Minggu berturut-turut hadir
StudentAgent	assignment_completion	[0, 1]	Rasio tugas yang diselesaikan
StudentAgent	ses_score	[0, 1]	Skor status sosial ekonomi
StudentAgent	learning_capacity	[0.6, 1.4]	Pengali kapasitas belajar individual
StudentAgent	grit	[0, 1]	Kegigihan menghadapi rintangan
LecturerAgent	teaching_effectiveness	[0.6, 1.4]	Kejelasan penyampaian materi
LecturerAgent	feedback_delay_weeks	{0,1,2,3,4}	Keterlambatan pengembalian nilai
LecturerAgent	assignment_load	{0,1,2,3}	Jumlah tugas per minggu

1.6.3 3.3 Inisialisasi

Pada awal simulasi (minggu 0), setiap `StudentAgent` diinisialisasi dengan nilai acak yang diambil dari distribusi yang dapat dikonfigurasi:

- `learning_capacity` $\sim$ `Uniform(0.60, 1.40)`: mencerminkan heterogenitas kemampuan belajar yang luas
- `knowledge` $\sim$ `TruncatedNormal( $\mu=0.35$ ,  $\sigma=0.10$ , [0,1])`: pengetahuan awal sedang

- `motivation` $\sim$ TruncatedNormal($\mu=0.65$, $\sigma=0.10$, $[0,1]$): motivasi awal cukup tinggi
- `stress` $\sim$ TruncatedNormal($\mu=0.25$, $\sigma=0.08$, $[0,1]$): stres awal rendah
- `ses_score` $\sim$ TruncatedNormal($\mu=0.50$, $\sigma=0.20$, $[0,1]$): keberagaman SES sedang (dapat dikonfigurasi)
- `grit` $\sim$ TruncatedNormal($\mu=0.60$, $\sigma=0.15$, $[0,1]$): kegigihan sedang, mengacu pada konstruk Duckworth et al. (2007)

Semua angka acak dibangkitkan menggunakan `numpy.random.default_rng(seed)` dengan *seed* yang ditentukan oleh pengguna, menjamin reproduisibilitas penuh. Semua nilai diklem (*clamped*) ke rentang valid setelah setiap pembaruan.

1.6.4 3.4 Aturan Pembaruan Mingguan

Setiap minggu, model menjalankan urutan pembaruan berikut untuk setiap mahasiswa yang masih aktif (belum putus studi).

1.6.4.1 3.4.1 Kehadiran Probabilitas kehadiran mahasiswa i pada minggu t dihitung sebagai:

```
p_attend(i,t) = base_attend
                + motivation(i,t) * w_mot
                - stress(i,t) * w_stress
                + ses_score(i) * w_ses
                + mode_mods["attendance_bonus"]
                - 0.15 * discomfort(room_temp)
```

di mana `base_attend` = 0.75, `w_mot` = 0.15, `w_stress` = 0.10, `w_ses` = 0.05, dan `discomfort` adalah fungsi ketidaknyamanan termal (lihat 3.4.7). Kehadiran aktual ditentukan melalui undian Bernoulli dengan probabilitas ini.

1.6.4.2 3.4.2 Penyelesaian Tugas Untuk setiap tugas yang diberikan pada minggu t , probabilitas penyelesaian tepat waktu dihitung berdasarkan motivasi, stres, dan kapasitas belajar mahasiswa. Tugas yang diselesaikan terlambat mendapat penalti nilai berdasarkan parameter *strictness* dosen.

1.6.4.3 3.4.3 Dinamika Stres Stres mahasiswa diperbarui melalui model aditif:

```
Δstress(i,t) = w_load * assignment_load
              + w_delay * pending_feedback_count(i,t)
              - w_feedback * feedback_received(i,t)
              - w_ses * ses_score(i)
              - w_attend * attend(i,t) * 0.05
              + mode_mods["fatigue_gain_mult"] * fatigue_gain_rate
```

Mahasiswa dengan stres tinggi secara berturut-turut (melebihi ambang `dropout_stress_threshold` selama `dropout_consecutive_weeks` minggu) ditandai sebagai *dropped out* dan dihapus dari simulasi aktif.

1.6.4.4 3.4.4 Dinamika Pengetahuan Perubahan pengetahuan mahasiswa setiap minggu dihitung sebagai:

$$\begin{aligned} \Delta \text{knowledge}(i,t) = & \text{learning_rate} \\ & \times \text{learning_capacity}(i) \\ & \times \text{teach_eff_effective}(t) \\ & \times \text{topic_dependency_factor}(i,t) \\ & \times \text{motivation}(i,t) \times (1 - \text{stress}(i,t)) \\ & \times \text{attend}(i,t) \\ & \times \text{peer_learning_contribution}(i,t) \\ & - \text{decay_rate} \times \text{knowledge}(i,t) \end{aligned}$$

di mana $\text{teach_eff_effective} = \text{teaching_effectiveness} \times \text{mode_mods}[\text{"teaching_effectiveness_mode"}]$ dan $\text{peer_learning_contribution}$ hanya aktif jika pembelajaran teman sebaya diaktifkan dalam konfigurasi.

$\text{topic_dependency_factor}$ merepresentasikan ketergantungan antarmateri: mahasiswa yang belum menguasai materi sebelumnya akan lebih kesulitan menyerap materi berikutnya. Faktor ini dihitung sebagai $(1 - \text{dep_strength}) + \text{dep_strength} \times \text{prereq_mastery}$, dengan $\text{dep_strength} = 0.40$.

1.6.4.5 3.4.5 Siklus Umpan Balik Ketika dosen mengembalikan nilai tugas setelah penundaan $\text{feedback_delay_weeks}$ minggu, mahasiswa yang menerimanya mengalami: - Penurunan stres sebesar $\text{stress_relief_from_feedback}$ - Peningkatan motivasi sebesar $\text{motivation_boost_from_feedback}$

Semakin panjang penundaan, semakin banyak nilai yang “menumpuk” (*pending feedback*), yang secara akumulatif meningkatkan stres mahasiswa.

1.6.4.6 3.4.6 Intervensi Tutoring Jika intervensi diaktifkan dan waktu berada dalam jendela $[\text{start_week}, \text{end_week}]$, mahasiswa yang berada di kuartil terbawah berdasarkan pengetahuan pada minggu deteksi risiko (default: minggu 5) menerima peningkatan motivasi dan pengurangan stres sebesar nilai yang dikonfigurasi (motivation_boost , stress_reduction) setiap minggunya.

1.6.4.7 3.4.7 Ketidaknyamanan Termal Fungsi ketidaknyamanan termal dihitung sebagai:

$$\text{discomfort}(\text{temp}) = \min(1.0, \max(0, (|\text{temp} - 22| - 2) / 8.0))$$

Fungsi ini bernilai 0 pada rentang 20–24°C (zona nyaman) dan meningkat secara linear di luar rentang tersebut, mencapai nilai 1.0 pada suhu di bawah 14°C atau di atas 30°C. Ketidaknyamanan termal mengurangi probabilitas kehadiran dan motivasi mahasiswa.

1.6.5 3.5 Formula IPK Proksi

Pada akhir semester (minggu 14), IPK proksi setiap mahasiswa dihitung sebagai:

$\text{raw_score} = \text{knowledge_final} \times 0.70 + \text{effective_completion} \times 0.30$
 $\text{gpa_proxy} = \text{raw_score} \times 4.0$

di mana *effective_completion* adalah rasio penyelesaian tugas yang disesuaikan dengan penalti keterlambatan dan parameter *strictness* dosen. IPK proksi diklasifikasikan sebagai *gagal (failure)* jika $\text{gpa_proxy} < 2.0$.

Bobot 70/30 antara pengetahuan dan penyelesaian tugas merepresentasikan asumsi umum bahwa nilai akhir seorang mahasiswa lebih didominasi oleh pemahaman materi (ujian akhir, ujian tengah semester) dibandingkan sekadar penyelesaian tugas harian. Serta komponen penyelesaian tugas didasarkan pada temuan Credé dan Kuncel (2008) bahwa kebiasaan belajar merupakan prediktor signifikan kinerja akademik yang bersifat komplementer terhadap kemampuan kognitif.

1.6.6 3.6 Desain Skenario

Sebelas skenario utama dirancang untuk menjawab kelima pertanyaan penelitian. Tabel 3.2 merangkum konfigurasi setiap skenario.

Tabel 3.2: Desain Skenario Eksperimen

Skenario	Mahasiswa	Delay (mgg)	Beban	SES Std	Intervensi	RQ
Baseline (Standar)	30	1	2	0.20	Tidak	Referensi
Kelas Kecil	15	1	2	0.20	Tidak	RQ1
Kelas Besar	60	1	2	0.20	Tidak	RQ1
Umpan Balik Segera	30	0	2	0.20	Tidak	RQ2
Umpan Balik Lambat	30	4	2	0.20	Tidak	RQ2
Beban Ringan	30	1	1	0.20	Tidak	RQ2
Beban Berat	30	1	3	0.20	Tidak	RQ2
Skenario Terburuk	60	4	3	0.20	Tidak	Kasus ekstrem
Program Tutoring	30	1	2	0.20	Mgg 7–10	RQ3
Keberagaman SES Tinggi	30	1	2	0.40	Tidak	RQ4
Paket Kebijakan Terbaik	30	0	1	0.20	Mgg 5–12	RQ2+RQ3

Selain 11 skenario di atas, empat skenario lingkungan fisik ditambahkan untuk menjawab RQ5: Kelas Panas (32°C), Kelas Dingin (16°C), Perkuliahan Daring Penuh, dan Perkuliahan Hibrida.

Tabel 3.3 memetakan keterkaitan antara setiap skenario dengan pertanyaan penelitian yang dijawab.

Tabel 3.3: Matriks Skenario x Pertanyaan Penelitian

Skenario	RQ1 (Ukuran Kelas)	RQ2 (Umpan Balik & Beban)	RQ3 (Intervensi)	RQ4 (SES)	RQ5 (Lingkungan)
Baseline (Standar)	Referensi	Referensi	Referensi	Referensi	Referensi
Kelas Kecil (15)	☐				
Kelas Besar (60)	☐				
Umpan Balik Segera (0 mgg)		☐			
Umpan Balik Lambat (4 mgg)		☐			
Beban Ringan (1/mgg)		☐			
Beban Berat (3/mgg)		☐			
Skenario Terburuk (60+3+4)	☐	☐			
Program Tutoring (mgg 7–10)			☐		
Keberagaman SES Tinggi				☐	

Skenario	RQ1 (Ukuran Kelas)	RQ2 (Umpan Balik & Beban)	RQ3 (Intervensi)	RQ4 (SES)	RQ5 (Lingkungan)
Paket Kebijakan Terbaik		☐	☐		
Kelas Panas (32°C)					☐
Kelas Dingin (16°C)					☐
Daring Penuh					☐
Hibrida					☐

1.6.7 3.7 Reprodusibilitas

Setiap simulasi menggunakan `numpy.random.default_rng(seed)` dengan nilai *seed* yang tersimpan bersama konfigurasi. *Seed* yang sama selalu menghasilkan keluaran yang identik (*deterministic reproducibility*). Berkas `config.json` disimpan bersama setiap hasil eksperimen, memungkinkan replikasi penuh.

1.6.8 3.8 Analisis Sensitivitas *One-at-a-Time* (OAT)

Untuk mengidentifikasi parameter kebijakan mana yang paling berpengaruh, dilakukan analisis sensitivitas *one-at-a-time* (OAT). Setiap parameter diubah dari nilai rendah ke nilai tinggi sementara semua parameter lain dipertahankan pada nilai baseline. Selisih metrik (Δ metric) dihitung relatif terhadap baseline, dan parameter diurutkan berdasarkan $|\Delta|$ terbesar.

Delapan parameter yang diuji adalah: ukuran kelas, keterlambatan umpan balik, beban tugas, efektivitas pengajaran, rerata SES, suhu ruangan, pembelajaran teman sebaya, dan mode kelas. Setiap konfigurasi dijalankan sebanyak `n_runs = 3 seed` untuk mengurangi *noise* stokastik.

1.6.9 3.9 Validasi Model

Model divalidasi melalui empat pendekatan:

1. **Validitas Wajah (*Face Validity*):** Arah semua efek diperiksa terhadap prediksi literatur (Hattie 2008, Shute 2008, ASHRAE 55). Kelas besar harus menghasilkan IPK lebih rendah; umpan balik lambat harus meningkatkan stres; suhu ekstrem harus mengurangi motivasi.
2. **Uji Determinisme:** Simulasi dijalankan dua kali dengan *seed* yang sama. Keluaran harus identik secara bit-per-bit. Uji ini memverifikasi tidak ada sumber non-determinisme tersembunyi.

3. **Uji Klem (*Clamp Test*):** Semua simulasi dijalankan dengan 100 *seed* acak. Semua variabel status harus tetap berada dalam rentang valid ($[0,1]$ untuk knowledge, stress, motivation, dll.) sepanjang 14 minggu.
4. **Uji Konvergensi:** Simulasi baseline dijalankan dengan $N = 10, 15, 20, 30, 45, 60, 90, 120$ mahasiswa, masing-masing 10 *seed*. IPK rata-rata beserta interval kepercayaan 95% (CI) dihitung untuk setiap N . Konvergensi tercapai jika CI menyempit seiring bertambahnya N , mengonfirmasi bahwa $N = 30$ cukup untuk estimasi yang stabil.

1.6.10 3.10 Asumsi dan Keterbatasan Model

Beberapa asumsi penting yang mendasari model ini, yang juga merupakan keterbatasan yang perlu diperhatikan dalam interpretasi hasil:

1. **Parameter bersifat ilustratif.** Nilai-nilai seperti `base_learning_rate = 0.28` atau `topic_dependency_strength = 0.40` dipilih agar menghasilkan pola kualitatif yang masuk akal, bukan dikalibrasi dari data empiris.
2. **Model putus studi disederhanakan.** Putus studi dimodelkan menggunakan heuristik stres tinggi berturut-turut, tanpa mempertimbangkan faktor psikososial yang lebih kompleks (Tinto, 1987).
3. **Kelompok belajar statis.** Jaringan pertemanan tidak berkembang secara dinamis selama semester.
4. **Satu mata kuliah, satu dosen.** Beban studi dari mata kuliah lain, kehadiran asisten dosen, atau tim pengajar tidak dimodelkan.
5. **Tekanan eksternal sebagai skalar.** Faktor-faktor seperti pekerjaan paruh waktu atau kewajiban keluarga direpresentasikan hanya sebagai satu parameter `external_pressure`.
6. **Tidak ada umpan balik real-time dari kelas nyata.** Model ini adalah *virtual twin / policy simulator*, bukan *digital twin* dalam arti penuh karena tidak terhubung dengan data LMS aktual (Rasheed et al., 2020).

1.7 BAB IV: HASIL DAN PEMBAHASAN

1.7.1 4.1 Hasil Skenario Baseline

Skenario baseline merepresentasikan kondisi kelas “standar”: 30 mahasiswa, keterlambatan umpan balik 1 minggu, 2 tugas per minggu, suhu ruangan 22°C, perkuliahan tatap muka, dan tidak ada program intervensi.


Tabel 4.1 menyajikan metrik ringkasan skenario baseline.

Tabel 4.1: Metrik Ringkasan Skenario Baseline

Metrik	Nilai
IPK Rata-rata (0–4)	3,01
Standar Deviasi IPK	0,40
Tingkat Kegagalan ($IPK < 2,0$)	0%
Tingkat Kehadiran Rata-rata	92,6%


Metrik	Nilai
Stres Akhir Rata-rata	0,21
Tingkat Putus Studi	0%

IPK rata-rata baseline 3,01 masuk dalam kategori “Sangat Memuaskan” pada skala penilaian perguruan tinggi Indonesia, mencerminkan kondisi kelas yang berjalan dengan baik tanpa tekanan berlebih. Gambar 4.1 menunjukkan evolusi pengetahuan rata-rata kelas selama 14 minggu simulasi, dengan pita ± 1 SD. Pengetahuan meningkat secara monoton sepanjang semester meskipun dengan kecepatan yang sedikit menurun menjelang akhir akibat akumulasi kelelahan mahasiswa.



Gambar 4.1: Evolusi pengetahuan rata-rata kelas (± 1 SD) selama 14 minggu simulasi (skenario baseline)

Gambar 4.2 menunjukkan profil stres yang tetap berada pada rentang moderat (0,21 pada akhir semester).



Gambar 4.2: Profil stres rata-rata kelas selama 14 minggu simulasi (skenario baseline)

1.7.2 4.2 Eksperimen Ukuran Kelas (RQ1)

Tiga skenario dibandingkan untuk menjawab RQ1: kelas kecil (15 mahasiswa), baseline (30), dan kelas besar (60).

Tabel 4.2: Perbandingan Ukuran Kelas


Skenario	IPK Rata-rata	Tingkat Kegagalan	Tingkat Kehadiran	Stres Akhir
Kelas Kecil (15)	3,17	0%	95,2%	0,22
Baseline (30)	3,01	0%	92,6%	0,21
Kelas Besar (60)	2,32	10%	93,9%	0,22

Hasil simulasi menunjukkan bahwa kelas besar (60 mahasiswa) menghasilkan IPK rata-rata 2,32, turun 0,70 poin dibandingkan baseline (3,01), sementara tingkat kegagalan naik dari 0% menjadi 10%. Kelas kecil (15 mahasiswa) menunjukkan IPK rata-rata 3,17, naik 0,16 poin dari baseline. Pola ini **menjawab RQ1 secara afirmatif**: ukuran kelas yang lebih besar berkorelasi negatif dengan kinerja akademik rata-rata dalam simulasi.

Untuk menginterpretasikan besaran dampak, selisih $-0,70$ poin pada kelas besar setara dengan **1,75 simpangan baku** distribusi baseline ($SD = 0,40$), yang tergolong *large effect size* berdasarkan konvensi Cohen ($d \geq 0,8$). Sebaliknya, peningkatan $+0,16$ poin pada kelas kecil setara dengan $0,40$ SD, tergolong *small-to-medium effect size*. Asimetri ini mengindikasikan bahwa kerugian akibat kelas besar jauh lebih besar daripada manfaat yang diperoleh dari memperkecil kelas.

Mekanisme di balik pola ini dapat dijelaskan sebagai berikut: pada kelas besar, efektivitas pengajaran per-mahasiswa menurun karena dosen memiliki kapasitas terbatas untuk memberikan perhatian individual. Seiring bertambahnya jumlah mahasiswa, penundaan umpan balik meningkat secara proporsional, yang berkontribusi pada akumulasi stres kelas.

Temuan ini konsisten dengan meta-analisis Hattie (2008) dan Glass & Smith (1979), meskipun *effect size* dalam simulasi ini bersifat ilustratif dan tidak dapat langsung dibandingkan secara numerik dengan studi empiris tersebut. Gambar 4.4 menunjukkan distribusi IPK proxy mahasiswa pada akhir semester untuk ketiga kondisi ukuran kelas.



Gambar 4.4: Distribusi IPK proxy mahasiswa pada akhir semester

1.7.3 4.3 Eksperimen Keterlambatan Umpun Balik (RQ2a)

Tiga kondisi dibandingkan: umpun balik segera (0 minggu), baseline (1 minggu), dan umpun balik sangat lambat (4 minggu).


Tabel 4.3: Perbandingan Keterlambatan Umpun Balik

Skenario	IPK Rata-rata	Tingkat Kegagalan	Stres Akhir
Umpun Balik Segera (0 mgg)	3,17	0%	0,21
Baseline (1 mgg)	3,01	0%	0,21
Umpun Balik Lambat (4 mgg)	2,22	30%	0,49

Tren yang konsisten terlihat: semakin lambat umpun balik dikembalikan, semakin tinggi stres dan semakin rendah IPK. Perpindahan dari umpun balik segera ke umpun balik 4 minggu menurunkan IPK sebesar 0,95 poin dan meningkatkan tingkat kegagalan dari 0% menjadi 30%. Selisih ini setara dengan **2,37 simpangan baku** distribusi baseline — efek terbesar yang diamati dari seluruh intervensi variabel tunggal yang diuji dalam penelitian ini. Pada skenario umpun balik 4 minggu, efek akumulasi (*pending feedback*) dari beberapa tugas yang belum dikembalikan secara bersamaan menghasilkan lonjakan stres dari 0,21 menjadi 0,49.

Temuan ini **mendukung RQ2a** dan konsisten dengan tinjauan Shute (2008) yang menemukan bahwa keterlambatan umpun balik di atas dua minggu secara signifikan mengurangi dampak positif umpun balik terhadap pembelajaran.

Gambar 4.3 menunjukkan perbandingan profil stres dari ketiga kondisi sepanjang 14 minggu, mengilustrasikan divergensi yang semakin besar antara kondisi umpun balik segera dan umpun balik lambat setelah minggu ke-5.



Gambar 4.3: Perbandingan IPK rata-rata seluruh skenario yang diuji

1.7.4 4.4 Eksperimen Beban Tugas (RQ2b)


Tiga tingkat beban tugas dibandingkan: ringan (1/minggu), standar (2/minggu), dan berat (3/minggu).

Tabel 4.4: Perbandingan Beban Tugas

Skenario	IPK Rata-rata	Tingkat Kegagalan	Stres Akhir
Beban Ringan (1/mgg)	3,09	0%	0,20
Baseline (2/mgg)	3,01	0%	0,21
Beban Berat (3/mgg)	2,72	6,7%	0,41

Skenario beban berat menghasilkan stres rata-rata yang lebih tinggi (0,41 vs 0,21) dan IPK yang lebih rendah (2,72 vs 3,01), sementara beban ringan menunjukkan hasil yang sedikit lebih baik. Pola ini **menjawab RQ2b secara afirmatif**. Selisih IPK $-0,30$ poin pada beban berat setara dengan **0,75 simpangan baku** distribusi baseline, tergolong *medium effect size* — lebih kecil dibandingkan dampak keterlambatan umpan balik (2,37 SD) maupun ukuran kelas (1,75 SD), yang konsisten dengan urutan prioritas dalam analisis OAT (lihat Bagian 4.9).

Meskipun pemberian tugas yang lebih banyak secara intuitif tampak mendorong mahasiswa untuk belajar lebih keras, dalam model ini peningkatan stres yang ditimbulkan justru mengurangi efektivitas pembelajaran, konsisten dengan mekanisme Yerkes-Dodson yang menjadi landasan model. Gambar 4.5 menampilkan evolusi motivasi rata-rata kelas, yang turut terpengaruh oleh akumulasi beban tugas.



Gambar 4.5: Evolusi motivasi rata-rata kelas selama 14 minggu simulasi

1.7.5 4.5 Skenario Kasus Terburuk

Skenario kasus terburuk menggabungkan kondisi paling merugikan secara bersamaan: 60 mahasiswa, 3 tugas per minggu, dan keterlambatan umpan balik 4 minggu. Dibandingkan dengan baseline:

- IPK rata-rata turun sebesar **1,30 poin** (dari 3,01 menjadi 1,72), setara dengan **3,25 simpangan baku** — jauh melampaui ambang *very large effect size*
- Tingkat kegagalan meningkat menjadi **90%**
- Tingkat putus studi mencapai **10%**

Temuan penting dari skenario ini adalah bahwa efek gabungan jauh lebih besar dibandingkan skenario tunggal terburuk sekalipun (keterlambatan umpan balik menghasilkan 30% kegagalan, bukan 90%), menunjukkan **efek interaksi non-linear** antara ukuran kelas, beban tugas, dan keterlambatan umpan balik. Ketika tekanan dari berbagai sumber menumpuk secara bersamaan, ambang putus studi mahasiswa jauh lebih mudah tercapai.

1.7.6 4.6 Eksperimen Program Tutoring (RQ3)

Skenario intervensi membandingkan kondisi baseline dengan kondisi di mana program tutoring diberikan kepada 25% mahasiswa berkinerja terendah pada minggu 7–10.

Sub-analisis dilakukan khusus untuk kelompok mahasiswa kuartil terbawah berdasarkan SES (Q1). Tabel 4.5 menunjukkan perbandingan.


Tabel 4.5: Dampak Program Tutoring pada Kuartil Terbawah

Kondisi	IPK Rata-rata (Seluruh Kelas)	IPK Rata-rata (Q1 Terbawah)	Tingkat Kegagalan (Q1)
Baseline	3,01	2,96	0%
Dengan Program Tutoring	3,08	3,06	0%

Kondisi	IPK Rata-rata (Seluruh Kelas)	IPK Rata-rata (Q1 Terbawah)	Tingkat Kegagalan (Q1)
Selisih (Delta)	+0,07	+0,10	0%

Hasil simulasi menunjukkan bahwa program tutoring berhasil meningkatkan IPK rata-rata mahasiswa kuartil terbawah sebesar 0,10 poin, sementara dampaknya terhadap IPK keseluruhan kelas sebesar +0,07. Peningkatan ini konsisten di seluruh 20 replikasi *seed* (Tabel 4.9). **RQ3 dijawab secara afirmatif**, meskipun dampaknya lebih terasa pada peningkatan IPK absolut mahasiswa lemah dibandingkan eliminasi kegagalan (karena tingkat kegagalan baseline sudah 0%).

Temuan tambahan dari Gambar 4.6: peningkatan pengetahuan kuartil terbawah mulai terlihat pada minggu ke-8, dengan tren positif yang berlanjut hingga akhir semester meskipun program berakhir pada minggu 10. Ini mengindikasikan adanya efek *momentum* dari intervensi yang berlanjut pasca-program.



Gambar 4.6: Profil putus studi dan perkembangan kelompok intervensi selama 14 minggu simulasi

1.7.7 4.7 Eksperimen Lingkungan Fisik dan Mode Perkuliahan (RQ5)

1.7.7.1 4.7.1 Suhu Ruangan Tiga kondisi suhu dibandingkan: kelas panas (32°C), baseline (22°C), dan kelas dingin (16°C).


Tabel 4.6: Perbandingan Suhu Ruangan

Skenario	IPK Rata-rata	Tingkat Kegagalan	Tingkat Kehadiran	Stres Akhir
Kelas Panas (32°C)	2,72	3,3%	79,5%	0,23
Baseline (22°C)	3,01	0%	92,6%	0,21

Skenario	IPK Rata-rata	Tingkat Kegagalan	Tingkat Kehadiran	Stres Akhir
Kelas Dingin (16°C)	2,87	0%	86,7%	0,22

Kedua kondisi suhu ekstrem menunjukkan penurunan IPK dibandingkan baseline. Kelas panas (32°C) menurunkan IPK sebesar 0,30 poin dengan dampak kehadiran yang signifikan (turun dari 92,6% menjadi 79,5%). Kelas dingin (16°C) menunjukkan dampak yang lebih kecil (IPK turun 0,15 poin). Pola ini konsisten dengan temuan Wargocki dan Wyon (2007).

Dalam konteks Indonesia, temuan ini memiliki relevansi praktis: banyak ruang kelas menghadapi masalah suhu tinggi akibat iklim tropis. Simulasi ini menunjukkan bahwa penyediaan sistem pendingin udara yang memadai berpotensi meningkatkan capaian akademik mahasiswa secara nyata. Gambar 4.7 menampilkan perbandingan tingkat kehadiran rata-rata pada kondisi suhu berbeda.



Gambar 4.7: Evolusi tingkat kehadiran rata-rata kelas selama 14 minggu simulasi

1.7.7.2 4.7.2 Mode Perkuliahan Tiga mode perkuliahan dibandingkan: tatap muka (baseline), hibrida, dan daring penuh.

Tabel 4.7: Perbandingan Mode Perkuliahan

Skenario	IPK Rata-rata	Tingkat Kegagalan	Tingkat Kehadiran	Stres Akhir
Tatap Muka	3,01	0%	92,6%	0,21
Hibrida	2,81	0%	93,8%	0,21
Daring Penuh	2,53	6,7%	95,2%	0,21

Perkuliahan daring penuh menunjukkan IPK rata-rata yang lebih rendah (2,53 vs 3,01), dengan

tingkat kegagalan 6,7%, meskipun tingkat kehadiran secara teknis lebih tinggi karena tidak ada hambatan fisik. Perkuliahan hibrida berada di antara keduanya (IPK 2,81).

Temuan ini **mendukung RQ5** dan konsisten dengan meta-analisis Means et al. (2010). Penting dicatat bahwa dalam model ini mode daring mengurangi efektivitas pengajaran dan laju pembelajaran teman sebaya; asumsi ini mungkin tidak berlaku jika desain pembelajaran daring dioptimalkan.

1.7.8 4.8 Eksperimen Keberagaman Status Sosial Ekonomi (RQ4)

Dua kondisi dibandingkan: baseline (std SES = 0,20) dan keberagaman SES tinggi (std = 0,40).


Tabel 4.8: Kesenjangan IPK Berdasarkan Kuartil SES

Skenario	IPK Q1 (SES Rendah)	IPK Q4 (SES Tinggi)	Kesenjangan (Q4 – Q1)
Keberagaman SES Sedang / Baseline (std=0,20)	2,96	3,17	0,21
Keberagaman SES Tinggi (std=0,40)	2,89	2,95	0,06

Hasil simulasi menunjukkan temuan yang menarik: kesenjangan IPK antara Q1 dan Q4 justru **lebih kecil** pada skenario keberagaman SES tinggi (0,06) dibandingkan baseline (0,21). Namun, IPK absolut mahasiswa Q1 pada skenario ses_diverse (2,89) lebih rendah dari baseline (2,96), mengonfirmasi bahwa mahasiswa SES rendah tetap dirugikan secara absolut.

Temuan ini sebagian konsisten dengan Sirin (2005) dalam hal dampak negatif SES rendah terhadap IPK absolut. Namun, hipotesis bahwa keberagaman lebih tinggi memperlebar kesenjangan antar-kuartil tidak terkonfirmasi dalam simulasi ini. Penjelasan yang mungkin adalah bahwa pada skenario ses_diverse, interaksi kelompok belajar yang lebih heterogen justru memberikan efek negatif merata ke semua kuartil, sehingga kesenjangan relatif antar-kuartil mengecil.

Temuan ini menyiratkan bahwa kebijakan pemerataan tetap relevan, terutama untuk meningkatkan IPK absolut mahasiswa SES rendah.




Gambar 4.8: Analisis kesenjangan IPK berdasarkan kuartil SES pada skenario baseline dan ses_diverse

1.7.9 4.9 Hasil Analisis Sensitivitas OAT

Gambar 4.9 menampilkan *tornado chart* dari analisis sensitivitas OAT terhadap metrik IPK rata-rata. Hasil analisis menunjukkan urutan dampak parameter sebagai berikut (dari terbesar ke terkecil):

1. **Keterlambatan umpan balik:** pengurangan dari 4 minggu ke 0 minggu meningkatkan IPK sebesar **0,95 poin**
2. **Ukuran kelas:** pengurangan dari 60 ke 15 mahasiswa meningkatkan IPK sebesar **0,85 poin**
3. **Efektivitas pengajaran:** peningkatan dari 0,7 ke 1,3 meningkatkan IPK sebesar **0,70 poin**
4. **Mode perkuliahan:** perubahan dari daring ke tatap muka meningkatkan IPK sebesar **0,48 poin**
5. **Beban tugas:** pengurangan dari 3 ke 1 tugas/minggu meningkatkan IPK sebesar **0,37 poin**
6. **Suhu ruangan:** perubahan dari 32°C ke 22°C meningkatkan IPK sebesar **0,30 poin**
7. **Pembelajaran teman sebaya:** pengaktifan meningkatkan IPK sebesar **0,18 poin**



Gambar 4.9: Analisis deteksi mahasiswa berisiko dan perbandingan antar-skenario

Temuan kunci dari analisis sensitivitas adalah bahwa **keterlambatan umpan balik mendominasi**, diikuti oleh ukuran kelas dan efektivitas pengajaran yang memiliki dampak serupa. Beban tugas, yang sering menjadi fokus keluhan mahasiswa, berada di peringkat kelima. Ini mengonfirmasi bahwa kualitas umpan balik, ukuran kelas, dan kualitas pengajaran adalah tiga faktor kebijakan yang paling strategis untuk ditingkatkan.

Implikasi praktis: program studi sebaiknya memprioritaskan kebijakan pengembalian nilai yang cepat sebelum mempertimbangkan restrukturisasi ukuran kelas, karena umpan balik memberikan dampak terbesar dengan biaya implementasi yang relatif rendah.

Catatan penting: analisis OAT mengasumsikan independensi antar-parameter. Kombinasi beban tugas tinggi dan keterlambatan umpan balik menunjukkan efek interaksi yang jauh melampaui prediksi aditif (lihat Bagian 4.5).

1.7.10 4.10 Uji Robustitas Multi-Seed

Untuk memastikan temuan direksional tidak bergantung pada satu *seed*, enam skenario kunci dijalankan masing-masing 20 kali dengan *seed* berbeda (0–19).

Tabel 4.9: Hasil Multi-Seed (20 Replikasi per Skenario)

Skenario	IPK Rata-rata $\pm$ CI95	Tingkat Kegagalan $\pm$ CI95
Baseline	3,04 $\pm$ 0,04	0,3% $\pm$ 0,4%
Umpan Balik Segera	3,17 $\pm$ 0,04	0,2% $\pm$ 0,3%
Umpan Balik Lambat	2,29 $\pm$ 0,04	26,8% $\pm$ 3,7%
Beban Berat	2,80 $\pm$ 0,04	3,2% $\pm$ 1,2%
Program Tutoring	3,11 $\pm$ 0,04	0,0% $\pm$ 0,0%
Daring Penuh	2,57 $\pm$ 0,04	8,0% $\pm$ 2,4%

Semua temuan direksional **terkonfirmasi** di seluruh 20 replikasi. Interval kepercayaan tidak tumpang tindih antar-skenario ekstrem (umpan balik segera 3,17 vs umpan balik lambat 2,29), mengindikasikan bahwa perbedaan yang ditemukan bersifat *robust* secara statistik dalam konteks simulasi ini.

1.7.11 4.11 Uji Konvergensi

Gambar 4.10 menampilkan hasil uji konvergensi: IPK rata-rata $\pm$ CI95 sebagai fungsi dari jumlah mahasiswa N (10, 15, 20, 30, 45, 60, 90, 120), masing-masing dihitung dari 10 *seed*.



Gambar 4.10: Dashboard eksekutif simulasi menampilkan ringkasan metrik kelas

CI semakin menyempit seiring meningkatnya N, mengonfirmasi bahwa simulasi menghasilkan estimasi yang semakin stabil. Pada N = 30 (baseline), CI sudah berada pada rentang $\pm 0,04$, cukup sempit untuk mendukung kesimpulan direksional. Nilai ini dipilih sebagai keseimbangan antara kestabilan statistik dan waktu komputasi yang wajar.

1.7.12 4.12 Ringkasan Seluruh Skenario

Tabel 4.10 merangkum hasil semua skenario yang dijalankan, berurutan dari IPK tertinggi ke terendah.

Tabel 4.10: Ringkasan Hasil Seluruh Skenario

Peringkat	Skenario	IPK Rata-rata	Delta vs Baseline	Tingkat Kegagalan	Putus Studi
1	Paket Kebijakan Terbaik	3,47	+0,46	0%	0%
2	Umpan Balik Segera	3,17	+0,16	0%	0%
3	Kelas Kecil (15)	3,17	+0,16	0%	0%
4	Beban Ringan	3,09	+0,08	0%	0%
5	Program Tutoring	3,08	+0,07	0%	0%
6	Baseline	3,01	—	0%	0%

Peringkat	Skenario	IPK Rata-rata	Delta vs Baseline	Tingkat Kegagalan	Putus Studi
7	SES Beragam	2,98	-0,03	0%	0%
8	Kelas Dingin (16°C)	2,87	-0,15	0%	0%
9	Hibrida	2,81	-0,21	0%	0%
10	Beban Berat	2,72	-0,30	6,7%	0%
11	Kelas Panas (32°C)	2,72	-0,30	3,3%	0%
12	Daring Penuh	2,53	-0,48	6,7%	0%
13	Kelas Besar (60)	2,32	-0,70	10%	0%
14	Umpan Balik Lambat	2,22	-0,79	30%	0%
15	Skenario Terburuk	1,72	-1,30	90%	10%

Paket Kebijakan Terbaik (*Best-Practice Bundle*), yang menggabungkan umpan balik segera, beban tugas ringan, dan program tutoring, menghasilkan IPK tertinggi (3,47) di antara semua skenario. Selisih antara skenario terbaik dan terburuk mencapai 1,75 poin IPK, menunjukkan bahwa pilihan kebijakan memiliki rentang dampak yang sangat besar terhadap capaian akademik mahasiswa.

1.7.13 4.13 Implikasi Kebijakan Akademik

Berdasarkan keseluruhan hasil eksperimen di atas, terdapat beberapa implikasi kebijakan yang dapat dipertimbangkan oleh institusi pendidikan tinggi.

Prioritas utama: percepatan pengembalian umpan balik. Analisis sensitivitas OAT menunjukkan bahwa keterlambatan umpan balik adalah faktor dengan dampak terbesar terhadap IPK (2,37 SD). Berbeda dari pengurangan ukuran kelas yang memerlukan penambahan tenaga pengajar, percepatan pengembalian tugas sering kali dapat diwujudkan melalui optimasi alur kerja penilaian atau pemanfaatan platform *Learning Management System* (LMS) dengan fitur umpan balik otomatis. Dengan kata lain, ini adalah intervensi berdampak besar dengan biaya implementasi yang relatif rendah.

Manajemen beban tugas secara hati-hati. Hasil simulasi menunjukkan bahwa kualitas dan ketepatan waktu umpan balik lebih menentukan capaian akademik dibandingkan kuantitas tugas. Penambahan tugas tanpa disertai kapasitas umpan balik yang memadai justru menurunkan IPK rata-rata. Program studi dapat mempertimbangkan pengurangan jumlah tugas jika sumber daya penilaian terbatas, sambil memastikan setiap tugas mendapatkan umpan balik yang cepat dan bermakna.

Intervensi bertarget lebih efisien daripada perubahan kebijakan menyeluruh. Program tutoring yang ditargetkan kepada 25% mahasiswa terendah (Seksi 4.6) menghasilkan peningkatan IPK kelompok terbawah sebesar +0,10 poin dengan biaya sumber daya yang jauh lebih kecil dibandingkan pengurangan ukuran kelas secara keseluruhan (+0,85 poin potensi dampak tetapi memerlukan

penggunaan kapasitas ruang kelas). Ini mengindikasikan bahwa identifikasi dini mahasiswa berisiko dan intervensi tepat sasaran dapat menjadi strategi yang efisien secara sumber daya.

Kondisi fisik ruang kelas tidak dapat diabaikan. Dalam konteks Indonesia yang beriklim tropis, suhu ruangan yang tinggi (32°C, tanpa AC) menurunkan kehadiran secara signifikan (−13,1 persen poin) dan IPK sebesar 0,75 SD. Investasi pada sistem pendingin udara yang memadai berpotensi memberikan *return on investment* yang terukur dalam bentuk peningkatan capaian akademik.

Dampak non-linear skenario gabungan. Kombinasi kondisi buruk secara bersamaan menghasilkan efek yang jauh lebih destruktif daripada jumlah dampak individual. Ini mengimplikasikan bahwa kebijakan pencegahan harus bersifat proaktif dan holistik — memperbaiki satu faktor saja tidak cukup jika faktor lain tetap dalam kondisi buruk.

1.7.14 4.14 Keterbatasan Model Simulasi

Hasil penelitian ini perlu diinterpretasikan dengan memperhatikan beberapa keterbatasan inheren dari model simulasi yang dikembangkan.

Pertama, asumsi perilaku yang disederhanakan. Model ini merepresentasikan motivasi, stres, dan proses pembelajaran mahasiswa melalui persamaan deterministik berbasis bobot parameter. Perilaku manusia nyata jauh lebih kompleks, tidak linear, dan dipengaruhi oleh faktor kontekstual yang tidak dimodelkan, seperti dinamika keluarga, kondisi kesehatan mental, atau pengaruh media sosial. Hasil simulasi karena itu tidak boleh diinterpretasikan sebagai prediksi perilaku individu.

Kedua, parameter model bersifat ilustratif, bukan empiris. Nilai-nilai parameter seperti *base_learning_rate*, *w_feedback*, dan *stress_threshold* diturunkan dari pertimbangan teoritis dan kalibrasi manual untuk menghasilkan pola yang masuk akal secara kualitatif. Tidak ada kalibrasi berbasis dataset empiris berskala besar yang dilakukan dalam penelitian ini. Oleh karena itu, besaran numerik absolut (misalnya, IPK 3,01 atau selisih 0,70 poin) tidak boleh diinterpretasikan secara harfiah sebagai prediksi kelas nyata.

Ketiga, homogenitas asumsi dosen. Model mengasumsikan satu dosen dengan parameter tetap sepanjang semester. Kenyataannya, kualitas pengajaran bervariasi antarindividu dan dapat berubah seiring waktu akibat kelelahan, motivasi, atau perbedaan pendekatan pedagogis. Variabilitas ini tidak dimodelkan dalam prototipe saat ini.

Keempat, validitas eksternal belum diuji. Sebagaimana dijelaskan pada Bagian 3.10, validasi yang dilakukan dalam penelitian ini terbatas pada validitas wajah (*face validity*) dan konsistensi internal. Kemampuan model untuk memprediksi kelas nyata secara kuantitatif — validitas eksternal — memerlukan kalibrasi parameter menggunakan data LMS aktual, yang merupakan arah penelitian lanjutan.

Kelima, konteks sosial yang disederhanakan. Jaringan pertemanan, dinamika kelompok, pengaruh media sosial, dan tekanan dari luar kampus tidak dimodelkan secara eksplisit. Faktor-faktor ini dapat memiliki dampak signifikan pada motivasi dan kinerja mahasiswa di kelas nyata.

Keterbatasan-keterbatasan di atas tidak mengurangi nilai kontribusi prototipe ini sebagai alat eksplorasi kebijakan berbasis bukti kualitatif. Namun, penelitian lanjutan yang mengintegrasikan data

empiris nyata diperlukan sebelum model ini dapat digunakan sebagai *digital twin* dalam pengertian prediktif penuh (Rasheed et al., 2020).

1.8 BAB V: KESIMPULAN DAN SARAN

1.8.1 5.1 Kesimpulan

Penelitian ini berhasil merancang, mengimplementasikan, dan memvalidasi sebuah prototipe *Class-room Ecosystem Digital Twin* berbasis simulasi berbasis agen untuk ekosistem kelas universitas satu semester (14 minggu). Berdasarkan eksperimen skenario yang dijalankan, berikut adalah jawaban atas kelima pertanyaan penelitian:

RQ1 — Pengaruh ukuran kelas: Ukuran kelas yang lebih besar (60 mahasiswa) menghasilkan IPK rata-rata yang lebih rendah dan tingkat kegagalan yang lebih tinggi dibandingkan kelas standar (30) maupun kelas kecil (15) dalam simulasi. Mekanisme utamanya adalah pengurangan efektivitas pengajaran per-mahasiswa dan akumulasi penundaan umpan balik yang lebih besar pada kelas besar.

RQ2 — Pengaruh keterlambatan umpan balik dan beban tugas: Keterlambatan umpan balik memiliki dampak negatif yang lebih besar terhadap IPK rata-rata dibandingkan peningkatan beban tugas saja. Pengurangan keterlambatan dari 4 minggu ke segera menghasilkan selisih IPK terbesar di antara semua intervensi yang diuji. Temuan ini konsisten dengan meta-analisis Shute (2008) dan Hattie (2008). Kombinasi beban tugas berat dan umpan balik sangat lambat (skenario terburuk) menghasilkan efek negatif yang bersifat *non-linear*, lebih buruk dari jumlah dampak individual.

Berdasarkan analisis sensitivitas OAT, **urutan prioritas faktor kebijakan berdasarkan besaran dampak terhadap IPK rata-rata adalah: umpan balik (+0,95) > ukuran kelas (+0,85) > efektivitas pengajaran (+0,70) > mode perkuliahan (+0,48) > beban tugas (+0,37)**. Implikasi langsungnya: program studi yang ingin meningkatkan kinerja mahasiswa sebaiknya memprioritaskan kebijakan pengembalian nilai yang cepat — faktor dengan dampak terbesar dan biaya implementasi yang relatif rendah — sebelum mempertimbangkan perubahan ukuran kelas yang membutuhkan investasi lebih besar.

RQ3 — Efektivitas program tutoring: Program tutoring selama 4 minggu (minggu 7–10) yang ditargetkan kepada 25% mahasiswa berkinerja terendah berhasil meningkatkan IPK rata-rata kuartil terbawah secara terukur. Terdapat efek *momentum* pasca-program: peningkatan berlanjut meskipun intervensi telah berakhir. Intervensi yang ditargetkan terbukti lebih efisien daripada perubahan kebijakan yang berlaku untuk seluruh kelas.

RQ4 — Keberagaman SES dan kesenjangan IPK: Hasil simulasi menunjukkan bahwa kohort dengan keberagaman SES tinggi (std = 0,40) tidak menghasilkan kesenjangan IPK antar-kuartil yang lebih besar dibandingkan baseline (std = 0,20); kesenjangan justru lebih kecil (0,03 vs 0,07). Namun, IPK absolut mahasiswa Q1 pada skenario *ses_diverse* (2,50) lebih rendah dari baseline (2,60), mengonfirmasi bahwa mahasiswa SES rendah tetap dirugikan secara absolut oleh keberagaman yang tinggi. Temuan ini sebagian konsisten dengan Sirin (2005) dalam hal dampak negatif SES rendah terhadap IPK absolut, namun tidak mengkonfirmasi hipotesis bahwa keberagaman lebih tinggi memperlebar kesenjangan antar-kuartil dalam konteks simulasi ini.

RQ5 — Faktor lingkungan fisik dan mode perkuliahan: Suhu ruangan di luar zona nyaman

(20–24°C), baik terlalu panas maupun terlalu dingin, mengurangi motivasi, kehadiran, dan IPK rata-rata. Kelas panas (32°C, kondisi tanpa AC) menunjukkan dampak yang lebih besar daripada kelas dingin (16°C). Perkuliahan daring penuh menghasilkan IPK rata-rata lebih rendah dibandingkan tatap muka akibat pengurangan efektivitas pengajaran dan pembelajaran teman sebaya; perkuliahan hibrida berada di antara keduanya.

Kesimpulan umum: Simulasi berbasis agen terbukti dapat menangkap pola kualitatif dinamika kelas yang konsisten dengan literatur psikologi pendidikan. Prototipe ClassTwin yang dikembangkan bersifat *open-source*, sepenuhnya dapat direproduksi, dan dilengkapi antarmuka *dashboard* untuk pengguna non-teknis, memenuhi kebutuhan alat analisis kebijakan kelas yang ringan dan interpretatif.

1.8.2 5.2 Validitas Model

Model ini telah divalidasi melalui empat mekanisme:

- **Validitas wajah:** Semua arah efek konsisten dengan prediksi literatur (Hattie 2008, Shute 2008, ASHRAE 55, Means et al. 2010).
- **Determinisme:** Simulasi dengan *seed* yang sama selalu menghasilkan keluaran yang identik.
- **Uji klem:** Semua variabel status tetap dalam rentang valid $[0,1]$ di seluruh 100 *seed* acak.
- **Konvergensi:** CI menyempit seiring meningkatnya N , mengonfirmasi bahwa $N = 30$ cukup untuk estimasi yang stabil.

Sebagaimana dijelaskan pada Bagian 3.10, validitas model bersifat **validitas wajah dan internal**; validitas eksternal (kemampuan model untuk memprediksi kelas nyata secara kuantitatif) membutuhkan kalibrasi parameter dengan data LMS nyata, yang merupakan pekerjaan masa depan.

1.8.3 5.3 Saran

Beberapa rekomendasi untuk pengembangan selanjutnya:

1. **Kalibrasi dengan data LMS nyata.** Menggunakan data anonim dari platform SPADA, Moodle, atau sistem LMS internal kampus untuk mengkalibrasi parameter seperti *base_learning_rate*, *stress_threshold*, dan *w_feedback*. Ini akan mengubah prototipe dari *virtual twin* menjadi *digital twin* dalam arti yang lebih penuh (Rasheed et al., 2020).
2. **Penambahan lapisan jaringan sosial.** Mengimplementasikan jaringan pertemanan yang dinamis di mana mahasiswa membentuk dan memodifikasi kelompok belajar sepanjang semester. Ini akan memungkinkan pemodelan efek *peer pressure*, difusi pengetahuan yang lebih realistis, dan dinamika *clique* sosial (Vygotsky, 1978).
3. **Perpanjangan ke kurikulum multi-mata-kuliah.** Mengembangkan model yang merepresentasikan rantai prasyarat mata kuliah lintas semester, memungkinkan simulasi dampak kebijakan di tingkat program studi atau kurikulum secara keseluruhan.
4. **Koneksi real-time dengan LMS.** Mengimplementasikan *pipeline* data yang mengambil data perilaku belajar aktual dari LMS secara periodik, memperbarui parameter agen secara dina-

mis, dan menggunakan model untuk memproyeksikan trajektori mahasiswa berisiko, mewujudkan *digital twin* dalam pengertian penuh (Baker & Yacef, 2009).

5. **Validasi lintas kampus.** Menjalankan studi perbandingan antara hasil simulasi dan data historis dari beberapa kampus berbeda di Indonesia untuk menilai generalisabilitas model.

1.9 DAFTAR PUSTAKA

Simulasi Berbasis Agen

- Bonabeau, E. (2002). Agent-based modeling: Methods and techniques for simulating human systems. *Proceedings of the National Academy of Sciences*, 99(Suppl. 3), 7280–7287.
- Gilbert, N. (2008). *Agent-based models*. SAGE Publications.
- Kazil, J., Masad, D., & Crooks, A. (2020). Utilizing Python for agent-based modeling: The Mesa framework. In *Social, Cultural, and Behavioral Modeling* (pp. 308–317). Springer.
- Macal, C. M., & North, M. J. (2010). Tutorial on agent-based modelling and simulation. *Journal of Simulation*, 4(3), 151–162.
- Squazzoni, F. (2012). *Agent-based computational sociology*. Wiley.
- Wilenski, U., & Rand, W. (2015). *An introduction to agent-based modeling*. MIT Press.

Digital Twin

- Batty, M. (2018). Digital twins. *Environment and Planning B: Urban Analytics and City Science*, 45(5), 817–820.
- Mousavi, Y., Gharineiat, Z., Aghakarimi, A., McDougall, K., Rossi, A., & Gonizzi Barsanti, S. (2024). Digital twin technology in built environment: A review of applications, capabilities and challenges. *Preprints*. <https://doi.org/10.20944/preprints202407.1004.v1>
- Grieves, M. (2014). Digital twin: Manufacturing excellence through virtual factory replication. *White Paper*.
- Rasheed, A., San, O., & Kvamsdal, T. (2020). Digital twin: Values, challenges and enablers. *IEEE Access*, 8, 21980–22012.
- Tao, F., Zhang, H., Liu, A., & Nee, A. Y. C. (2019). Digital twin in industry: State-of-the-art. *IEEE Transactions on Industrial Informatics*, 15(4), 2405–2415.

Psikologi Pendidikan dan Pembelajaran

- Duckworth, A. L., Peterson, C., Matthews, M. D., & Kelly, D. R. (2007). Grit: Perseverance and passion for long-term goals. *Journal of Personality and Social Psychology*, 92(6), 1087–1101.
- Kahneman, D. (1973). *Attention and effort*. Prentice-Hall.
- Lazarus, R. S., & Folkman, S. (1984). *Stress, appraisal, and coping*. Springer.
- Ryan, R. M., & Deci, E. L. (2000). Self-determination theory and the facilitation of intrinsic motivation. *American Psychologist*, 55(1), 68–78.
- Tinto, V. (1987). *Leaving college: Rethinking the causes and cures of student attrition*. University of Chicago Press.

- Vygotsky, L. S. (1978). *Mind in society: The development of higher psychological processes*. Harvard University Press.
- Yerkes, R. M., & Dodson, J. D. (1908). The relation of strength of stimulus to rapidity of habit-formation. *Journal of Comparative Neurology and Psychology*, 18(5), 459–482.

Umpan Balik dan Ukuran Kelas

- Credé, M., & Kuncel, N. R. (2008). Study habits, skills, and attitudes: The third pillar supporting collegiate academic performance. *Perspectives on Psychological Science*, 3(6), 425–453.
- Glass, G. V., & Smith, M. L. (1979). Meta-analysis of research on class size and achievement. *Educational Evaluation and Policy Analysis*, 1(1), 2–16.
- Hattie, J. (2008). *Visible learning: A synthesis of over 800 meta-analyses relating to achievement*. Routledge.
- Shute, V. J. (2008). Focus on formative feedback. *Review of Educational Research*, 78(1), 153–189.

Status Sosial Ekonomi dan Kesenjangan Pendidikan

- Sirin, S. R. (2005). Socioeconomic status and academic achievement: A meta-analytic review of research. *Review of Educational Research*, 75(3), 417–453.

Kenyamanan Termal

- ASHRAE. (2017). *ANSI/ASHRAE Standard 55: Thermal environmental conditions for human occupancy*. ASHRAE.
- Wargocki, P., & Wyon, D. P. (2007). The effects of outdoor air supply rate and supply air temperature on cognitive performance. *HVAC&R Research*, 13(6), 867–882.

Analitik Pembelajaran dan Data Pendidikan

- Ardianti, M., Nurhayati, O. D., & Warsito, B. (2023). Model prediksi kinerja siswa berdasarkan data log LMS menggunakan ensemble machine learning. *JST (Jurnal Sains dan Teknologi)*, 12(3), 562–571. <https://doi.org/10.23887/jstundiksha.v12i3.59816>
- Baker, R. S., & Yacef, K. (2009). The state of educational data mining in 2009: A review and future visions. *Journal of Educational Data Mining*, 1(1), 3–17.
- Romero, C., & Ventura, S. (2007). Educational data mining: A survey from 1995 to 2005. *Expert Systems with Applications*, 33(1), 135–146.

Pembelajaran Daring dan Hibrida

- Means, B., Toyama, Y., Murphy, R., Bakia, M., & Jones, K. (2010). *Evaluation of evidence-based practices in online learning*. U.S. Department of Education.

Pendidikan Tinggi Indonesia

- Direktorat Jenderal Pendidikan Tinggi (DIKTI). (2023). *Statistik pendidikan tinggi Indonesia 2023*. Kementerian Pendidikan, Kebudayaan, Riset, dan Teknologi.

1.10 LAMPIRAN

1.10.1 Lampiran A — Tabel Referensi Parameter

Tabel A.1 merangkum semua parameter `SimulationConfig` beserta nilai default, rentang yang dapat dikonfigurasi, dan deskripsi singkat.

Parameter	Default	Rentang	Deskripsi
<code>n_students</code>	30	5–120	Jumlah mahasiswa dalam kelas
<code>n_weeks</code>	14	8–20	Durasi semester (minggu)
<code>seed</code>	42	sembarang	<i>Seed</i> RNG untuk reproduibilitas
<code>teaching_effectiveness</code>	1.0	0.6–1.4	Efektivitas pengajaran dosen
<code>feedback_delay_weeks</code>	1	0–4	Keterlambatan pengembalian nilai (minggu)
<code>assignment_load</code>	2	0–3	Jumlah tugas per minggu
<code>strictness</code>	0.5	0–1	Penalti keterlambatan tugas
<code>ses_score_mean</code>	0.5	0–1	Rerata SES mahasiswa
<code>ses_score_std</code>	0.2	0–0.5	Standar deviasi SES (keberagaman)
<code>room_temp_celsius</code>	22.0	10–40	Suhu ruangan kelas (°C)
<code>class_mode</code>	<code>in_person</code>	<code>in_person/hybrid/online</code>	Mode perkuliahan
<code>enable_peer_learning</code>	<code>True</code>	<code>Bool</code>	Aktifkan pembelajaran teman sebaya
<code>intervention.enabled</code>	<code>False</code>	<code>Bool</code>	Aktifkan program tutoring
<code>intervention.start_week</code>	7	1–13	Minggu mulai intervensi
<code>intervention.end_week</code>	14	1–14	Minggu selesai intervensi

1.10.2 Lampiran B — Cara Menjalankan Simulasi

Persyaratan:

```
Python 3.10+
pip install -r requirements.txt
```

Menjalankan antarmuka *dashboard*:

```
streamlit run src/app/streamlit_app.py
```

Menjalankan semua skenario dari *command line*:

```
python -m src.experiments.runner  
# Keluaran disimpan ke data/<timestamp>/
```

Menghasilkan laporan tesis:

```
# Melalui antarmuka: klik "Generate Thesis Report" di tab Campus Board  
# Atau via kode:  
from src.experiments.runner import ScenarioRunner  
runner = ScenarioRunner()  
runner.run_all(tag="thesis")
```

1.10.3 Lampiran C — Reproduksi Semua Gambar

Semua gambar dalam tesis ini dapat direproduksi dengan menjalankan:

```
python -m src.experiments.runner  
# Gambar disimpan ke data/<timestamp>/plots/
```

Dengan *seed* default (42), keluaran akan identik dengan gambar yang ditampilkan dalam tesis ini.